

使用 jiebaR 及 wordcloud2 进行中文分词和词云图绘制

—— 大语言模型辅助编程

2024.4

传统做法（被动）

- 课程课本
- 模仿学习
- 网络资料

我想知道词云图是什么 —— 查资料

- Google
- 知乎
- 简书...

找编程的示例 —— 查资料

- Google
- 知乎
- CSDN...

学习编程

- 包
- 函数调用：语法、参数
- 数据：加载、处理
- Debug —— 查资料

大模型（ChatGPT、Kimi）辅助（主动）

- 明确需求
- 提问沟通
- 反复修改

我想知道词云图是什么 —— 对话

- Google
- 知乎
- 简书...

找编程的示例 —— 对话

- 使用R语言编写一个词云图的例子

学习编程

- 包
- 函数调用：语法、参数
- 数据：加载、处理
- Debug —— 复制 bug 解答修改
- 修改程序某一部分

ChatGPT 3.5 ▾



How can I help you today?

Suggest fun activities
to do indoors with my high-energy dog

Create a workout plan
for resistance training

Explain airplane turbulence
to someone who has never flown before

Explain superconductors
like I'm five years old

Message ChatGPT...



历史会话

手机版



文件，拖进来；网址，发出来

Enter 发送; Shift + Enter 换行



试试这些超长文本的例子~

【Longer than long】Kimi 支持200万字上下文输入了！

【Prompt征集活动】突击检查！！交出你的Kimi玩法！

【量子速读】请帮我读一篇最新的AI论文 <https://arxiv.org/html/2401.10220v1>

【关于我们】讲给对Moonshot AI好奇的你 [关于Moonshot AI.pdf](#)

- 直接搜索 kimi
- 网址: <https://kimi.moonshot.cn/>
- 手机号、微信即可注册
- 免费、无需翻墙、可上传文件分析



Hi, 我是 Kimi~

很高兴遇见你！你可以随时把网址🔗或者文件📎发给我，我来帮你看看

kimi是什么？怎么使用



Kimi 是一个由月之暗面科技有限公司开发的人工智能助手，它能够进行中文和英文的对话，提供安全、有帮助、准确的回答。Kimi 擅长处理多种类型的文件，包括文本、PDF、Word 文档、PPT 幻灯片和 Excel 电子表格等，并且能够阅读和解析这些文件的内容，以便更好地回答用户的问题。

使用 Kimi 的方法非常简单：

1. **提问**：直接向 Kimi 提出问题，无论是关于知识、信息查询还是文件内容的解读。
2. **上传文件**：如果需要帮助解读文件内容，可以将文件发送给 Kimi，Kimi 会阅读文件内容后回复你。
3. **使用搜索**：如果问题需要通过搜索来解答，Kimi 可以结合搜索结果提供答案。

此外，Kimi 还有一些特定的使用方式：

- **PC 端使用**：可以在 [Kimi 的 PC 端网页](#) 上使用。
- **App 使用**：Kimi 也有一个 App，可以在 [App 下载地址](#) 下载使用，并且支持语音输入和输出。

Kimi 会遵循中华人民共和国的法律，并且会拒绝回答涉及恐怖主义、种族歧视、黄色暴力、政治敏感等问题。

现在，你可以开始向 Kimi 提问或者上传文件了。

复制 再试一次 分享





词云图是什么



词云图的主要特点包括：

1. **直观性**：通过不同大小的字体直观展示单词的重要性或频率。
2. **简洁性**：以简洁的形式展示大量文本信息的关键词。
3. **可定制性**：用户可以根据需要调整词云图的颜色、形状、字体等。
4. **装饰性**：词云图可以设计得很有吸引力，常用于装饰和设计领域。

词云图通常用于以下场景：

- **社交媒体分析:** 展示热门话题或标签。
- **文本挖掘:** 快速识别文档集中的关键词。
- **品牌监控:** 追踪品牌或产品在网络中的提及情况。
- **市场研究:** 了解消费者对某个话题的讨论焦点。

词云图的生成通常涉及以下步骤：


1. 文本处理：包括去除标点符号、转换为小写（对于区分大小写的语言）、去除停用词等。
2. 分词：将文本分解成单词或词汇单元。
3. 词频统计：计算每个单词或词汇单元的出现频率。
4. 词云图生成：根据词频数据，使用特定的软件或库生成词云图。

尽管词云图在视觉上很吸引人，但它们也有局限性，例如难以展示复杂的数据关系，且可能会因为设计选择而产生误导。因此，词云图通常作为补充其他数据分析方法的一种工具。





通常使用什么工具绘制？包含什么步骤？



常用工具：

1. 在线生成器:

- Wordle
- WordArt
- WordArt.com

2. 桌面软件:

- Adobe Illustrator (或其他图形设计软件)

3. 编程库:

- Python: wordcloud库
- R: wordcloud和wordcloud2包
- JavaScript: d3-cloud或wordclouds.com



绘制步骤：

1. **文本准备**：收集并准备好你想要在词云图中展示的文本数据。
2. **文本预处理**：
 - 清洗文本：去除无关字符，如数字、特殊字符等。
 - 分词：将文本分解成单词或词汇单元。
 - 去除停用词：移除常见的、意义不大的词汇，如“的”、“和”、“是”等。
3. **词频统计**：计算每个单词或词汇单元的出现频率。
4. **选择工具**：根据你的需求选择合适的词云图生成工具。
5. **配置参数**：
 - 字体大小：通常与词频成正比。
 - 颜色：可以选择单一颜色或多种颜色。
 - 形状：词云可以是矩形、圆形或自定义形状。
 - 布局：调整单词的排列方式。
6. **生成词云图**：使用所选工具根据配置的参数生成词云图。
7. **调整和优化**：根据生成的词云图效果进行调整，可能需要多次迭代。
8. **输出和分享**：将生成的词云图保存为图像文件，并根据需要进行分享或进



一、wordcloud2 绘制词云图



使用R语言中的wordcloud2制作一个词云图示例



要使用R语言中的wordcloud2包制作词云图，你需要先安装并加载这个包。以下是一个简单的示例，展示了如何使用wordcloud2包来创建一个词云图。

首先，确保你已经安装了wordcloud2包，如果没有安装，可以使用以下命令进行安装：

```
install.packages("wordcloud2")
```

然后，加载wordcloud2包，并使用一些示例文本数据来创建词云图：

```
# 加载wordcloud2包
library(wordcloud2)

# 示例文本数据，这里我们使用一个简单的向量
text_data <- c(
  "词云图", "R语言", "数据分析", "数据可视化", "词云图",
  "数据科学", "统计学", "机器学习", "数据挖掘", "R语言"
)

# 将文本数据转换为词频表
word_freq <- table(unlist(text_data))

# 生成词云图
wordcloud2(word_freq, size = 0.5)

# 你还可以通过设置不同的参数来定制词云图的外观，例如：
# - shape 可以设置词云的形状
# - color 可以设置字体的颜色
# - backgroundColor 可以设置背景颜色
# - fontFamily 可以设置字体类型
# 等等...
```

上面的代码会生成一个简单的词云图，其中每个单词的大小与其在文本数据中出现的频率成正比。wordcloud2函数的size参数控制字体大小的范围。

请注意，这只是一个非常基础的示例。在实际应用中，你可能需要从一个文本文件、数据库或网页中提取文本数据，并进行适当的预处理，比如分词、去除停用词等，然后再生成词云图。



- 制作词云图代码的基本结构是什么？
- 如何更改这里面的“文本数据”？
- 我想要更改词云图的颜色、形状
- wordcloud 和 wordcloud2 有什么关系？
- wordcloud具体语法是什么？
-

demoFreqC是该包自带的中文数据集



demoFreq是该包自带的英文数据集



```
library(wordcloud2)
wordcloud2(demoFreqC, size = 1, fontFamily = "微软雅黑",
           color = "random-light", backgroundColor = "black", shape='star')
```





```
wordcloud2(data, size = 1, color = 'random-dark', backgroundColor = "white", minRotation = -  
pi/4, maxRotation = pi/4, rotateRatio = 0.4, shape = 'circle' )
```

常用参数:

- (1) data: 词云生成数据, 包含具体词语以及频率;
- (2) size: 字体大小, 默认为1, 一般来说该值越小, 生成的形状轮廓越明显;
- (3) fontFamily: 字体, 如 '微软雅黑' ;
- (4) fontWeight: 字体粗细, 包含 'normal' , 'bold' 以及 '600' ; ;
- (5) color: 字体颜色, 可以选择 'random-dark' 以及 'random-light' , 其实就是颜色色系;
- (6) backgroundColor: 背景颜色, 支持R语言中的常用颜色, 如 'gray' , 'black' ;
- (7) minRontatin与maxRontatin: 字体旋转角度范围的最小值以及最大值, 选定后, 字体会在该范围内随机旋转;
- (8) rotationRation: 字体旋转比例, 如设定为1, 则全部词语都会发生旋转;
- (9) shape: 词云形状选择, 默认是 'circle' , 即圆形。还可以选择 'cardioid' (苹果形或心形) , 'star' (星形) , 'diamond' (钻石) , 'triangle-forward' (三角形) , 'triangle' (三角形) , 'pentagon' (五边形) ;

- 注意输入的逗号、引号
应在英文输入下
- [官方包中的例子](#)

二、jiebaR 中文分词





在绘制词云图的时候，为什么要进行中文分词



在绘制中文词云图的时候，进行中文分词是非常重要的一步，原因如下：

1. **中文特性**：与英文等使用空格分隔单词的语言不同，中文文本通常没有明显的单词分隔符。中文分词（Chinese Word Segmentation）是将连续的中文字符序列切分成有意义的单词的过程。
2. **提高准确性**：通过分词，可以将文本中的句子或短语准确地分割成单独的词汇，这样才能正确地统计每个词汇的出现频率，进而在词云图中正确地反映它们的权重。
3. **去除噪声**：分词过程中，可以一并去除文本中的标点符号、数字、无意义的字符等噪声信息，这样可以提高词云图的质量，使其更加直观地展示文本的主题和关键词。
4. **停用词过滤**：在分词的同时，通常还会移除一些停用词（如“的”、“和”、“是”等），这些词汇在中文中非常常见，但对传达文本的主题意义帮助不大。去除这些词汇可以让词云图更加突出重要信息。
5. **优化显示效果**：分词后，可以根据词汇的实际意义和上下文关系来调整词云图的显示效果，比如调整某些词汇的大小、颜色或布局，以更好地传达信息。
6. **提升可读性**：正确的分词可以确保词云图中的词汇是可读和易于理解的，避免将句子或短语错误地分割成无意义的片段。

在R语言中，可以使用jiebaR包来进行中文分词，该包基于Python中非常流行的jieba分词库。使用jiebaR进行分词后，就可以使用wordcloud或wordcloud2等包来创建词云图了。

```
# 加载wordcloud2包
library(wordcloud2)

# 使用简单的文本字符串作为例子
text <- "Kimi is a great AI assistant. Kimi can help you with many things. Kimi is very helpful."

# 将文本字符串分割成单词
words <- unlist(strsplit(text, " "))

# 计算单词的频率
word_freq <- table(words)

# 将结果转换为数据框格式
word_freq_df <- data.frame(word = names(word_freq), freq = as.numeric(word_freq))

# 使用wordcloud2函数生成词云图
wordcloud2(word_freq_df, size = 0.5, color = "random-dark", backgroundColor = "white")
```

• 如果替换成中文句子呢？

Kimi 是一个很棒的人工智能助手。Kimi 可以帮助你做很多事情。Kimi 非常有帮助。





介绍一下jiebaR这个包，并且给一个例子



jiebaR 是一个用于R语言的包，它提供了中文分词的功能，以及一些其他与中文文本处理相关的工具。jiebaR 是对Python中非常流行的 jieba 分词库的R语言实现。这个包可以帮助你处理中文文本数据时，将连续的文本分割成有意义的词汇，从而为后续的文本分析和挖掘工作打下基础。

以下是 jiebaR 包的一些主要功能：

1. **中文分词**：将中文文本分割成单独的词汇。
2. **添加自定义词典**：用户可以添加自定义的词典来提高分词的准确性。
3. **关键词提取**：根据给定的文本，提取关键词。
4. **词性标注**：为分词结果添加词性标注。

安装 jiebaR

你可以使用以下命令来安装 jiebaR 包：

```
install.packages("jiebaR")
```

加载 jiebaR

安装完成后，使用以下命令加载包：

```
library(jiebaR)
```

使用 jiebaR 进行中文分词的示例

```
# 加载jiebaR包
library(jiebaR)

# 示例中文文本
text <- "自然语言处理是人工智能领域中的一个重要方向。"

# 使用jiebaR进行中文分词
words <- worker(text, toLower = TRUE)

# 查看分词结果
print(words)
```

在这个例子中，worker 函数用于分词，toLower = TRUE 参数表示将结果转换为小写。分词结果是一个包含分词文本的列表。

添加自定义词典

有时候，jiebaR的默认词典可能不符合我们的需求，这时候我们可以添加自定义词典来提高分词的准确性：

```
# 添加自定义词典
add_dictionary("my_dict.txt")

# 重新进行分词
words <- worker(text, toLower = TRUE)

# 查看分词结果
print(words)
```

在这个例子中，add_dictionary 函数用于添加自定义词典，参数是词典文件的路径。

jiebaR 是处理中文文本数据的强大工具，尤其适用于需要进行中文分词的数据分析和文本挖掘任务。

- 如何更改这里面的“示例文本”？
- 中文分词只有worker这一个函数么？
- worker函数语法是什么？多来几个例子？
-

```
> demoFreq
```

	word	freq
oil	oil	85
said	said	73
prices	prices	48
opec	opec	42
mln	mln	31
the	the	26
last	last	24
bpd	bpd	23
dlrs	dlrs	23
crude	crude	21
market	market	20
reuter	reuter	20
saudi	saudi	18
will	will	18
one	one	17
barrel	barrel	15

```
install.packages("jiebaR")
```

```
library("jiebaR")
```

```
work <- worker() #用到worker()函数，赋值给work
```

```
work["这是一个中文分词的例句。"] #方括号中是要进行分词的语句
```

```
> library("jiebaR")
```

```
> work <- worker() #用到worker()函数，赋值给work
```

```
> work["这是一个中文分词的例句。"] #方括号中是要进行分词的语句
```

```
[1] "这是" "一个" "中文" "分词" "的" "例句"
```

如果语句比较长，可以换种写法：

```
juzi <- "杭州的四月真美丽，想到西湖边吹吹风。
```

```
灵峰和孤山的梅花，龙井八景的桃花，太子湾的郁金香，
```

```
白堤间株的桃柳，八卦田的油菜花，美不胜收。" #用juzi替代长句子
```

```
work <- worker()
```

```
work[juzi] #方式一
```

```
work <= juzi #方式二
```

```
segment(juzi,work) #方式三
```



- worker()和segment()语法:** jiebaR通过函数worker()来初始化分词引擎, 使用函数segment()进行分词。

```
worker(type = "mix", dict = DICTPATH, hmm = HMMPATH, user = USERPATH,  
       idf = IDFPATH, stop_word = STOPPATH, write = T, qmax = 20, topn = 5,  
       encoding = "UTF-8", detect = T, symbol = F, lines = 1e+05,  
       output = NULL, bylines = F, user_weight = "max")
```

参数	用法
type	分词引擎类型。这个包包括mix, mp, hmm, full, query, tag, simhash, keyword, 分别指混合模型, 支持最大概率, 隐马尔科夫模型, 全模式, 索引模型, 词性标注, 文本Simhash相似度比较, 关键字提取。
dict	词库路径, 默认为DICTPATH.
hmm	用来指定隐马尔可夫模型的路径, 默认值为DICTPATH, 当然也可以指定其他分词引擎
user	用户自定义的词库
idf	用来指定逆文本频率指数路径, 默认为DICTPATH, 也可以用于simhash和keyword分词引擎
stop_word	用来指定停用词的路径
write	是否将文件分词结果写入文件, 默认FALSE
qmax	词的最大查询长度, 默认为20, 可用于query分词类型。
topn	关键词的个数, 默认为5, 可以用于simhash和keyword分词类型
encoding	输入文件的编码, 默认UTF-8
detect	是否编码检查, 默认TRUE
symbol	输出是否保留符号, 默认为F
lines	从文件中最大一次读取的行数。默认为1e+05
output	输出文件, 文件名一般时候系统时间。
bylines	返回输入的文件有多少行
user_weight	用户词典的词权重, 有"min" "max" or "median"三个选项。

worker()参数释义

```
segment(code, jiebar, mod = NULL)
```

比worker简单多啦

参数	用法
code	中文句子或者文件
jiebar	设置分词的引擎, 也就是worker函数
mod	改变默认的分词引擎类型, 其中包括以下几个: "mix", "hmm", "query", "full", "level", "mp"

[更详细的jiebaR教程](#)

三、实例





- 商品评价.csv —— 对该文件中“评价内容”一栏进行 分词 和 词云图 绘制
- 额外要求
 - 去除掉字符数只有1的无意义词
 - 只取频数大于等于5的词汇

会员	级别	评价星级	评价内容
鸿***腾		star5	物流很快，一直很信任京东！包装完整，东西很好，第一次用微软的这个，体验中！都是办公应急用，估计可以满足日常需求！
F***N		star5	纠结了很久灰色还是蓝色，最后选了蓝色，超级好看，个人很喜欢~电脑也很赞，超清的屏幕，很便携，功能不错，自己再慢慢开发，买来呀
白***8		star5	物流很快 昨晚买的 下午就送到了 平板也非常赞
z***1		star5	一开始只是为了买部电脑用而已，用了几天发现特别适合备考，不装键盘听课件下面放书正好。和s u rface属于先结婚后恋爱，很喜欢！另
j***j		star5	不错，特别喜欢京东的物流速度。心心念念的face pro 终于入手，见到实物爱不释手，外观好看新颖时尚，酒红色的键盘也特别典雅！
l***7		star5	挺好看的，应该还不错，现在上手第一天。屏幕分辨率也很好。这个价钱还是可以的。赞
c***1		star5	刚收到了，快递非常敬业，外观漂亮，屏幕清晰,不错的一款平板电脑
宝***子		star5	东西确实不错，很漂亮，买来是给老公写代码，学习用的，非常方便，买过苹果的PDA，个人更推荐这款产品,功能多，限制少，方便，插上
h***u		star5	朋友买过整体体验下来非常好，这次给妈妈买。
文***嫣		star5	本来还是准备买一台IBM的，觉得这款贵没必要，老公坚持要买这款，收到货后觉得还是挺值得，首先他真的是超薄款啊，比传统的笔记本
j***a		star5	真的好漂亮啊，比期待的更漂亮，键盘酒红色，手感超好，屏幕也好，触感很灵敏，赶紧买了个膜贴上了。总之就是好好好，不枉费我抛弃
r***o		star5	试用有感很好很方便，尤其是键盘，两种模式切换很舒服，办公感和休闲感都用的上，出差神器
l***3		star5	收到了很好看呢，搭配机器非常简单清新。质感也非常nice！很满意！派送也很及时~
y***n		star5	买的套装，推荐同事也买过，感觉不论从颜值还是性能都能满足，非常好的产品。
j***p		star5	挺好用的，系统自带的办公软件很给力，买了不后悔
s***r		star5	虽然不错 很方便小巧 随王玲着





- 上传文件（注意文件路径）
- 不同的对话方式（通常来说，按步骤对需求进行拆解可以使返回结果更准确、或者说，需求越明确，给出的结果越精准）
 - 使用R语言绘制这个文件中“评价内容”一栏的词云图
 - 使用R语言绘制这个文件中“评价内容”一栏的词云图，使用wordcloud2并且使用jiebaR进行中文分词
 - 使用R语言绘制这个文件中“评价内容”一栏的词云图，可能的步骤为：1. 提取评价内容并整合；2. 使用jiebaR对整合内容进行中文分词；3. 使用wordcloud2进行词云图绘制
- Debug
- 按需增加限制
 - 去除掉字符数只有1的无意义词
 - 只取频数大于等于5的词汇
- Debug
- 按照自己的喜好修改样式



```
install.packages("wordcloud")
install.packages("wordcloud2")
install.packages("jiebaR")
install.packages("jiebaRD")
install.packages('devtools')
devtools::install_github("leeshuheng/cnSentimentR")

# 加载所需要的包
library(wordcloud)
library(wordcloud2)
library(jiebaRD)
library(jiebaR)
# 读取数据
word = read.csv("/Users/a133/Downloads/2.csv", header=F, encoding="UTF-8")
# 提取数据
wd = paste(word[,4], sep="", collapse="")
# 创建分词引擎
mixseg <- worker("mix")
# 分词和词频统计
kd <- segment(wd, jiebar=mixseg)
kd <- kd[nchar(kd)>1] # 筛选掉字符数只有1的无意义词
sd <- data.frame(table(kd)) # 统计各个词的频数
sd <- sd[sd$Freq>5,] # 只保留频数多于5的词
sd <- sd[order(sd$Freq, decreasing=TRUE),] # 排序
# 绘制词云图
wordcloud2(sd)
```



```
library(jiebaR)
library(wordcloud2)

# 读取CSV文件
evaluations <- read.csv("/Users/a133/文件/商品评价.csv", encoding = "UTF-8")

wd = paste(evaluations[,4],sep=" ",collapse = "")

# 提取评价内容并整合在一起
evaluation_text <- paste(evaluations$评价内容, collapse = " ")

work <- worker()
words = work[evaluation_text]
words <- words[nchar(words)>1]

# 计算单词的频率
word_freq <- table(words)

# 将结果转换为数据框格式
word_freq_df <- data.frame(word = names(word_freq), freq = as.numeric(word_freq))
word_freq_df <- word_freq_df[word_freq_df$freq>5]

# 使用wordcloud2函数生成词云图
wordcloud2(word_freq_df, size = 0.5, color = "random-dark", backgroundColor = "white")
```