

课程概述

王尧

西安交通大学智能决策与机器学习中心
(Email: yao.s.wang@gmail.com)

2024. 4

个人简历

■ 教育经历

- 电子科技大学信息与计算科学学士
- 西安交通大学应用数学硕士、博士(导师: 徐宗本院士)
- 西安交通大学管理科学与工程博士后(合作导师: 廖貅武教授)

■ 工作经历

- 美国佐治亚理工学院工业与系统工程系联合培养博士
- 西安交通大学统计系讲师、副教授
- 西安交通大学信息系统与智能商务系副教授/博导、教授/博导(2023.5至今)

■ 研究兴趣

- 机器学习与运筹优化的融合交叉(如大规模混合整数规划的求解)
- 动态环境下的序列决策(如动态推荐与选品优化)
- 高维数据分析(如图像与视频分析)

课程要求

■ 课程主要目标

- 共32学时
- 掌握数据挖掘与分析的现代机器学习方法(机器学习三驾马车)
- 会用R或Python语言结合chatgpt编程处理实际生活中的数据挖掘问题

■ 学习形式

- 组成学习小组，每组2-4人
- 除了教师授课以外，课后需完成一些课程实验

■ 考核方式

- 程序实验报告：2-3份(小组形式)，占比50%
- 大作业(小组形式)，占比50%

课程主要内容

■ 数据分析语言基本介绍

- R语言及其基本操作
- Python语言及其基本操作

■ 现代回归方法

- 最小二乘回归
- 正则化回归方法(数据挖掘三驾马车之glmnet)

■ 现代分类方法



- Logistic回归
- 决策树与Boosting算法(数据挖掘三驾马车之gbm)
- bagging与随机森林算法(数据挖掘三驾马车之randomForest)

■ 爬虫与数据清洗简介

■ 应用举例

- 欺诈行为检测
- 大模型与AIGC

参考书籍



参考书籍

Trevor Hastie

home

biography

research

software & data

lectures

students

publications


links

MY PUBLICATIONS


BOOKS ■ ■ ■

■ Books


- [Papers - 2016](#)
- [Papers - 2015](#)
- [Papers - 2014](#)
- [Papers - 2013](#)
- [Papers - 2012](#)
- [Papers - 2011](#)
- [Papers - 2010](#)
- [Papers - 2009](#)
- [Papers - 2008](#)
- [Papers - 2007](#)
- [Papers - 2006](#)
- [Papers - 2005](#)
- [Papers - 2004](#)
- [Papers - 2003](#)
- [Papers - 2002](#)
- [Papers - 2001](#)




[Computer Age Statistical Inference: Algorithms, Evidence and Data Science](#)
by Bradley Efron and Trevor Hastie (August 2016)
[Book Homepage](#)
[pdf \(8.5 Mb, corrected online\)](#)



[Statistical Learning with Sparsity: the Lasso and Generalizations](#)
by Trevor Hastie, Robert Tibshirani and Martin Wainwright (May 2015)
[Book Homepage](#)
[pdf \(10.5Mb, corrected online\)](#)





[An Introduction to Statistical Learning with Applications in R](#)
by Gareth James, Daniela Witten, Trevor Hastie and Robert Tibshirani (June 2013)
[Book Homepage](#)
[pdf \(9.4Mb, 6th corrected printing\)](#)



[The Elements of Statistical Learning: Data Mining, Inference, and Prediction \(Second Edition\)](#)
by Trevor Hastie, Robert Tibshirani and Jerome Friedman (2009)
[Book Homepage](#)
[pdf \(13Mb, correct. 11th print\)](#)

<http://web.stanford.edu/~hastie/pub.htm>

参考书籍中文版



ISL

An Introduction to Statistical Learning

Download ISL with R

Download ISL with Python

Springer Texts in Statistics

Gareth James
Daniela Witten
Trevor Hastie
Robert Tibshirani

An Introduction to Statistical Learning

with Applications in R

Second Edition

Springer Texts in Statistics

Gareth James · Daniela Witten · Trevor Hastie ·
Robert Tibshirani · Jonathan Taylor

An Introduction to Statistical Learning

with Applications in Python

<https://www.statlearning.com>

课程最低要求

悬赏百万美金检测Deepfake假视频，数据集470G：比赛很久没这么壕

原创 量子位 2019-12-13 13:51:52

车栗子 发自 凹非寺
量子位 报道 | 公众号 QbitAI

谁说Kaggle比赛都那么穷？

穷不穷，还要看做的是什么任务。

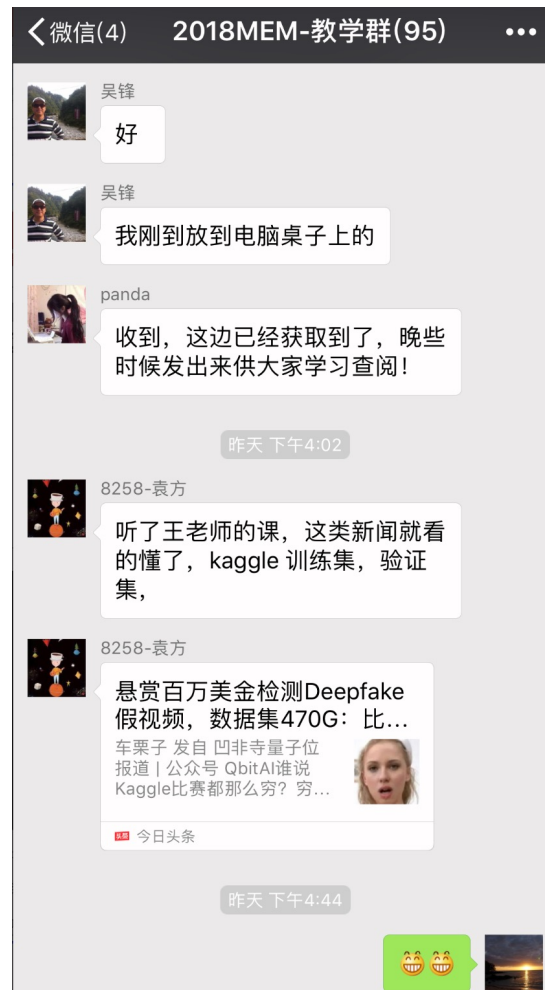
比如，有左右两段视频，你能分辨哪个是修过的么：





动图结尾公布了答案，右是原始视频，左是Deepfake之后。

就算肉眼也很难分辨，如果有AI能够胜任，重金奖励也不奇怪吧：

刚刚，就有一场捉拿假视频的Kaggle挑战赛启动了，奖池总额高达100万美元。



课程最低要求




课程高阶要求

研究问题：针对大数据背景下小企业信用风险评级问题，将基于贝叶斯参数优化的集成学习模型与现有的信用评分方法相结合，提出一个分类精确度高、耗时较少，并且可解释的信用评级模型。

采用数据：采用邮储银行 1820 个工业型小企业+Kaggle 信贷数据集+UCI 公开数据集。

研究内容：中小企业融资难，从根本上来说是中小企业与金融机构之间的信息不对称引起的，如何通过信用评级模型合理有效的评估中小企业的信用风险状况对于解决中小企业融资难、融资贵问题起着决定性的作用。信用评分或者信用评估本质是一个二分类问题，即将客户区分为两类：好客户（非违约客户）和坏客户（违约客户），其中分类器的选择至关重要。合适的模型能够准确识别出违约客户，减少银行或金融机构的损失。另外可解释性也很重要，由于金融机构往往需要解释拒绝原因，一些如 SVM 这样的权重通常不是特征重要性代表的模型实用性收到限制。所以本文将主要的集成模型包括 Xgboost、LightGBM 等方法与贝叶斯优化结合作为分类器对客户进行评分，与一些经典的 LDA 方法、逻辑回归方法、Z-score 方法进行比较。要求是在在提升传统分类器模型预测精度的基础上，降低机器学习模型超参数优化时间。再使用最优的模型进行指标筛选和信用评级评级。



课程高阶要求

2020MEM论文指导(3)

...



h z b

有的



h z b

用的light GBM

Nov 16, 2021 10:11



h z b

特征找的是常见的macd、KDJ、rsi的衍生

有点意思



哈哈哈哈哈



我先看看



看看后面涨的如何👍



h z b

我们回测了19年到21年的收益，大概是2.4倍，高于沪深300指数，比创业板300指数略高，回撤15%



h z b

年化大概是33%

2020MEM论文指导(3)

...

Nov 17, 2021 12:13



h z b



Nov 17, 2021 12:14



h z b

爱康科技涨停走掉了，我体会到了用知识赚钱的快乐~机器学习yyds

哇塞厉害，哈哈

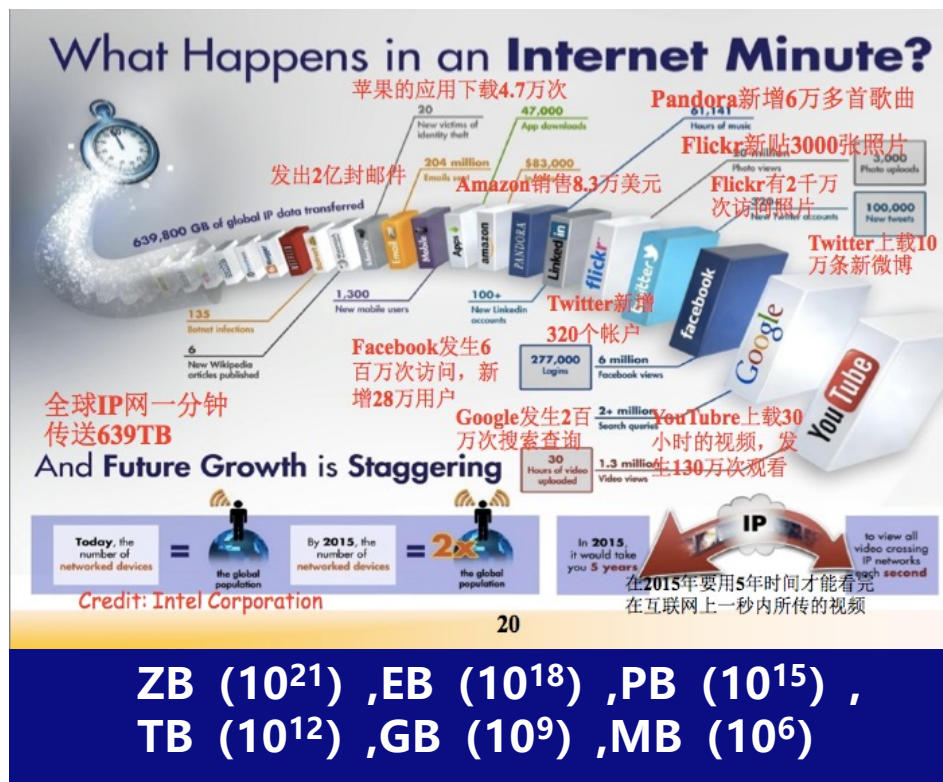


我们争取搞个更好的模型出来



什么是数据？

- 历史的记录、交易的轨迹、过程的监控、经验的累积、……
- 数据：以编码形式存在的信息载体，是真实世界的碎片化反映



什么是大数据？ 常规定义

大数据是指无法在容许的时间内用常规的软件工具对其内容进行抓取、管理和处理的数据集合，大数据规模的标准是持续变化的，当前泛指单一数据集的大小在十几TB和PB之间。（**维基百科**）

体量浩大、生长快速、模态众多、价值巨大（但密度低）的数据集。

大数据=现有数据处理技术难以处理的超大规模数据

Volume

- PB—ZB 量级
- 不可能集中存储
- 不可能集中处理



Velocity

- 动态增长、时变
- 以数据流呈现，有时效性
- 必须实时处理



Variety

- 形式、来源多样
- 冗余、不完全并存
- 非结构化



Value

- 存在大价值
- 但依赖整体
- 价值密度低



什么是大数据？泛化定义

泛指**一个时代、一项技术、一种文化、一个挑战**。（通常也是大数据集、大数据技术与大数据应用的总称）




拥有大数据是时代特征、解读大数据是时代任务、应用大数据是时代机遇！

(大数据时代)



能够对复杂海量数据进行实时获取、传输、存储、加工和利用的高新技术！

(大数据技术)



我们信奉上帝，除了上帝任何人都要以数据说话！

(大数据文化)



现有的数据采集、传输、存储、处理与分析技术已无法适用于现有的需要！

(大数据挑战)

什么是大数据？更本质定义

大数据的“大”

反映真实世界的数据
(碎片) 其量已达到
可以从一定程度上反
映其真实面貌的程度。

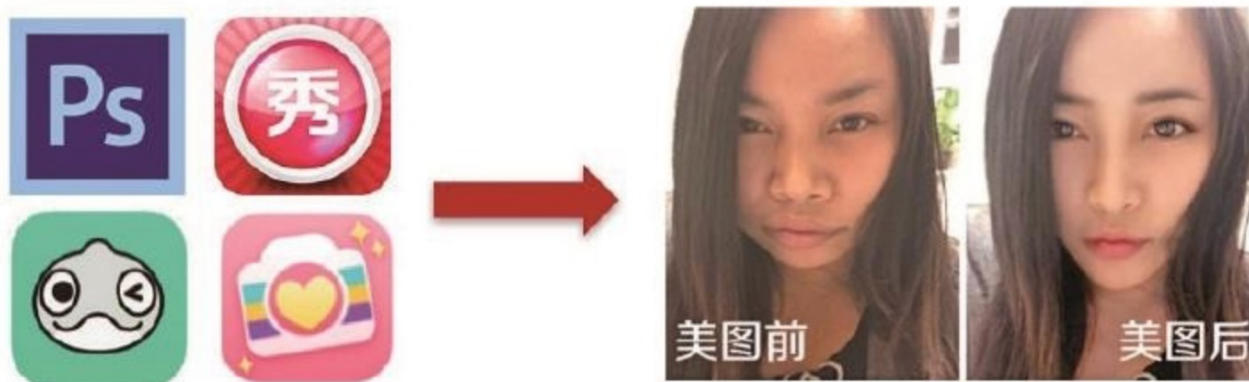
(量变 → 质变)

“大”是一个相对的概念



数据举例-生活中的图像处理

美颜修图软件层出不穷



自拍图像质量成为手机新卖点



图像处理可以帮助我们提取、理解甚至改变图像信息

图像数据



熊大.jpg
(尺寸 301×296)

从R读

```
1.00000000 1.00000000 1.00000000
1.00000000 1.00000000 1.00000000
1.00000000 1.00000000 0.96862745
0.94117647 0.89411765 0.80392157
0.48235294 0.48235294 0.45490196
0.38039216 0.38431373 0.36470588
0.30196078 0.28627451 0.25882353
0.35294118 0.30588235 0.24313725
0.29803922 0.25490196 0.20000000
0.24313725 0.20784314 0.17254902
0.16078431 0.14117647 0.12549020
0.10196078 0.09411765 0.09411765
0.09803922 0.09019608 0.09019608
0.12941176 0.11764706 0.10588235
0.12941176 0.11372549 0.09019608
0.10588235 0.09019608 0.07058824
0.10196078 0.09803922 0.08235294
```

一个有301×296×3个元素的数组
尺寸代表像素点的个数，每个像素点
包含红绿蓝三种颜色的信息



灰度图

图像的灰度图可以由RGB彩色图像计算得到，其计算公式有很多，例如取三个通道的均值或者加权均值等。



熊大.jpg
(尺寸 301×296)

灰化的熊大



灰度图
(尺寸 301×296)


储存方式

```
1.00000000 1.00000000 1.00000000
1.00000000 1.00000000 1.00000000
1.00000000 1.00000000 0.96862745
0.94117647 0.89411765 0.80392157
0.48235294 0.48235294 0.45490196
0.38039216 0.38431373 0.36470588
0.30196078 0.28627451 0.25882353
0.35294118 0.30588235 0.24313725
0.29803922 0.25490196 0.20000000
0.24313725 0.20784314 0.17254902
0.16078431 0.14117647 0.12549020
0.10196078 0.09411765 0.09411765
0.09803922 0.09019608 0.09019608
0.12941176 0.11764706 0.10588235
0.12941176 0.11372549 0.09019608
0.10588235 0.09019608 0.07058824
0.10196078 0.09803922 0.08235294
```

一个有301×296个元素的矩阵
每个元素代表一个像素点的灰度值

分辨率

图像分辨率指图像中存储的信息量，与图像像素点有关，更本质地说，和图片背后的**像素矩阵中的数据**有关，而这也是传说中“马赛克”的基础。



分辨率

灰色熊大：20×20



灰色熊大：50×50



灰色熊大：100×100



灰色熊大：200×200



不同分辨率的图像

图像的数学运算

`display(X1+0.5)`



`display(X1-0.5)`



为什么大数据会热？

- 新一轮信息技术革命与人类社会经济活动交汇融合必然产生大数据；
- 大数据从信息载体这一底层(一个更普适、更本质的角度)捕捉到了信息化的共性基础、未来发展与普适技术。

物联网作为
联接人、机、
环境的基本
交互方式

大数据处理
与分析是**信
息处理的基本
形式**

新一轮 信息技术 革命

互联网、云
存储作为基
本的**基础设
施**

服务计算作
为计算机应
有的**基本模
式**

数据化(Datafication)时代

大数据能干什么？

获取

传输

存储

处理 + 分析

决策



统计

(电商、语音识别等)



排序

(网页排序、推荐系统等)




融合

(互联网 +)




查询

(google翻译、风险、信用评估等等)




比对

(电商等)




预处理

(对齐、配准、标准化等)




发展趋势预测

(负荷预测等)



关联性

(设备交叉故障等)




关键要素分析

(售电量影响因素分析等)




共性结构发现

(电力客户细分等)



模式识别

(设备故障诊断等)



优化与控制

(电力调度等)

大数据应用举例-智慧生活



滴滴、美团、曹操



打车服务

GIS云平台



数据处理与分析平台

云计算平台



家庭装修



手机

位置
人员
.....



出租车

位置
人员
车牌
.....



大数据应用举例-投资分析

英国Derwent Capital Markets对冲基金公司建立了规模为4000万美金的对冲基金，该基金是首家基于社交网络的对冲基金，该基金**通过大数据分析技术对Twitter 的海量数据内容来构建情感分析模型，用来感知市场情绪，进行实时分析，从而指导进行投资。**



传统预测模型



新预测模型

效益

- 模型准确度从**73%**提高到**87%**
- 年化收益率从**9%**提高到**22%**

应用举例-精准营销




针对不同应用偏好的客户群组，精选同类热门应用，开展线上精确营销。

财经类偏好用户营销

游戏类偏好用户营销

音乐类偏好用户营销

偏好客户



第三方应用策略分析

针对20万的财经类偏好客户，按照ARPU由高到低推荐第三方手机证券应用、财经类新闻应用；

针对22万游戏类偏好用户，按照客户群体划分，推荐第三方手机QQ游戏等应用；

针对76万音乐类偏好用户，按照客户操作系统分类，推荐天天动听等三方音乐类应用；

应用效果

<手机证券（大智慧版）>：用手机炒股，为您把握投资良机：实时监控市场动向，给你最权威的决策分析！
发送量：51619
点击量：2632 点击率：5.1%
下载量：1084 下载率：2.1%

还在玩<愤怒的小鸟>你out啦！<捣蛋猪>已强势来袭！飞天小猪成主角，快来享受60多个关卡带来的飞行乐趣吧！
发送量：69000
点击量：4485 点击率：6.5%
下载量：2415 下载率：4.3%

<天天动听>：播放、音效、下载样样行！海量歌词同步，最新最准！更有中国好声音实力唱将最热曲目，音乐达人的你值得拥有！
发送量：87620
点击量：4118 点击率：4.7%
下载量：2541 下载率：2.9%


大数据应用举例-电子商务

亚马逊于2013年12月获得了一项名为“**预测式发货**”的新专利。



基于经验的传统备货--->基于大数据的精准备货

大数据应用举例-公共安全



某派出所 2014-3-7 早班巡防时段 (8:00-17:00)的犯罪预测信息



2014年12月31日上海外滩事件。当天19点-20点大幅度超过历史平均人数的一倍以上，此时应预警；22-23点基本达到峰值，超过历史平均人数8-9倍



大数据应用举例-社会治理

2012年的美国大选中，奥巴马组建专业的数据分析团队，竞选团队将接近1/4的精力放在大数据挖掘和分析上，结果表明在数字营销上的花销是最高产出的投入。



- 在获取的关于每个选民的600个信息点间**寻找关联**
(如：挑出乔治柯鲁尼在西海岸助选)
- 在选民与选民之间搭建联系，**划分成100亚群体**

- Twitter/Facebook等社交网络上的活动记录
- 杂志订阅情况
- 获取视频信息的主要途径
- 对特定时政新闻的观点态度
-

数据



大数据处理与分析平台

所有这些应用说明了什么？

①数据具有重大价值！（全新的思维方式、产业形态、营销模式和管理方式）



②数据挖掘应用模式（数据、平台、应用）



所有这些应用说明了什么？



③明确目标是前提，拥有数据是基础，计算平台是支撑，
数据分析与挖掘是核心，产生效益是根本

所有这些应用说明了什么？


④ 现有的应用多集中于基础设施建设（云平台、数据中心、计算架构等），所展现的成功应用基本上以查询处理为基础的技术，分析还仅限于传统方法所及（统计分析、数据挖掘），仍是非常初等的！



云平台



查询处理



数据中心



统计分析、
数据挖掘

大数据与人工智能

人工智能热潮来袭；新一代人AI发展规划实施；重大科技项目全面启动。


国务院2017发布《新一代人工智能发展规划》；科技部启动重大科技专项



人工智能发展三阶段：技术应用先行，基础理论紧随，全面超越领先。
国家公布首批人工智能开放创新平台；先发优势，企业主体、市场主导。

大数据与人工智能

- 人工智能三大核心驱动力（兴起由之，发展由之）
 - ✓ **脑科学/认知科学进展（算法）**
 - ✓ **数据分析与挖掘技术（大数据）**
 - ✓ **计算机能力（计算能力）**
- 人工智能生态：
 - ✓ **算法（深度学习）**
 - ✓ **芯片（GPU）**
 - ✓ **软硬件系统（tensorflow、Pytorch）**
 - ✓ **应用（自动驾驶、人脸识别、智慧医疗、...）**
- 可见趋势: 大数据+场景+**数据分析与挖掘**;
由感知智能向认知智能发展



生成式人工智能

路径1：文本到文本AIGC

ChatGPT是由OpenAI基于GPT-3.5 开发的大型语言模型聊天机器人



AIGC

五大技术应用方向

路径5：图像到图像AIGC

由Preferred Networks推出的Crypko可以创作上半身动漫形象。



Crypko

从草稿中创作图像



修复损坏的图像



AIGC




路径3：文本到3DAIGC

谷歌推出的DreamFusion可以根据给定的文本创建3D模型

DreamFusion

请为我生成一个使用笔记本电脑的3D机器人



AIGC

让这个机器人来模仿我的语气吧



AIGC

创作一些音乐



AIGC

Murf AI推出的人类语音生成器可以在几分钟内发出录音室质量的声音

MURF

路径4：音频相关AIGC

我怎么能去超市？

直走，然后向左转。

AIGC

请给我画一张显示道路的地图



AIGC

请给我画一幅非常愤怒的小鸟



AIGC

Imagen

由谷歌推出的Imagen，是一个文本到图像的扩散模型，具有前所未有的摄影现实感和深刻的语言理解水平

路径2：文本到图像AIGC

生成式人工智能

AI Video Generator

Available credits: 0 ?

Pricing

Log in

Generate

History

Text prompt

Image or video ? 1/1000 |clear

Reset

Generate

Examples:



Retry Re-prompt Edit Add 4s

Super saturated color, fireworks over a field at sunset.



Retry Re-prompt Edit Add 4s

1950s film, old shepherd on a mountain with a goat, facing camera



Retry Re-prompt Edit Add 4s

River



Retry Re-prompt Edit Add 4s

cinematic shot, extreme close up dolly shot on a stylish japanese girl with dreads standing on a pink desert



Retry Re-prompt Edit Add 4s


cinematic shot, dolly in shot on an italian male cook



Retry Re-prompt Edit Add 4s

A Santa is skiing on a snowboard, snowy, Christmas vibe

大数据科学与在职教育



Know how an
**MBA in Data Science
& Data Analytics**
will transform your life



STANFORD GRADUATE
BUSINESS SCHOOL OF

Big Data, Strategic Decisions: Analysis to Action

Overview Curriculum Faculty Participant Profile

MIT
MANAGEMENT
SLOAN SCHOOL

Dive deep into data science. Apply here.



復旦大學 管理学院
SCHOOL OF MANAGEMENT
FUDAN UNIVERSITY

数据科学与商务分析硕士项目
Master of Science in Data Science and Business Analytics

什么是数据挖掘？

- 数据挖掘是一门从大规模数据中提取信息，并将其转换成可理解的结构，以进一步使用的科学，其本质上属于机器学习范畴。
- 从直观的数学角度来看，数据挖掘可考虑为：假定我们已观测到响应变量 Y 以及 p 个不同的输入变量 $X_1, X_2, \dots, X_p$ ，那么有如下数学模型：

$$Y = f(X) + \epsilon$$

- f 为一固定但未知的函数
- ϵ 为随机误差项，通常假设其均值为0且与 X 无关
- 数据挖掘的核心目标即为如何设计有效的方法准确地估计 f 。

一个简单例子




FIGURE 2.1. The **Advertising** data set. The plot displays **sales**, in thousands of units, as a function of **TV**, **radio**, and **newspaper** budgets, in thousands of dollars, for 200 different markets. In each plot we show the simple least squares fit of **sales** to that variable, as described in Chapter 3. In other words, each blue line represents a simple model that can be used to predict **sales** using **TV**, **radio**, and **newspaper**, respectively.

上图来源于ISLR第17页

为什么要估计 f ?

- 预测：对于任一输入数据 X ，我们可预测其响应输出为

$$\hat{Y} = \hat{f}(X)$$

- $\hat{f}$ 是通过某种方法得到关于 f 的估计
- $\hat{Y}$ 是关于真实但未知的 Y 的估计

- 推理：在很多场景下，我们不仅仅需要对新输入数据的预测，还关心 Y 是如何被 X 所影响的，譬如：

- 哪些输入变量真正影响 Y ？
- 每个变量对 Y 的影响程度大小到底如何？
- 每个变量对 Y 的影响形式有什么差异？

如何估计 f ?

从哪里学



训练数据

(, 狗)(, 狗)(, 猫)(, 猫)
(, 狗)(, 狗)(, 猫)(, 猫)
 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

如何估计 f ?




FIGURE 2.4. A linear model fit by least squares to the **Income** data from Figure 2.3. The observations are shown in red, and the yellow plane indicates the least squares fit to the data.

上图来源于ISLR第22页

$$\text{income} \approx \beta_0 + \beta_1 \times \text{education} + \beta_2 \times \text{seniority}$$

无监督学习

- ▶ **Unsupervised learning:** discovering structure

E.g., given measurements $X_1, \dots, X_n$, learn some underlying group structure based on similarity

- ▶ **Supervised learning:** making predictions

I.e., given measurements $(X_1, Y_1), \dots, (X_n, Y_n)$, learn a model to predict Y_i from X_i

简单聚类实例




FIGURE 2.8. A clustering data set involving three groups. Each group is shown using a different colored symbol. Left: The three groups are well-separated. In this setting, a clustering approach should successfully identify the three groups. Right: There is some overlap among the groups. Now the clustering task is more challenging.

上图来源于ISLR第27页

R Project



[\[Home\]](#)

Download

[CRAN](#)

R Project

[About R](#)

[Logo](#)

[Contributors](#)

[What's New?](#)

[Reporting Bugs](#)

[Development Site](#)

[Conferences](#)

[Search](#)

R Foundation

[Foundation](#)

[Board](#)

[Members](#)

[Donors](#)

[Donate](#)

Help With R

[Getting Help](#)

Documentation

[Manuals](#)

[FAQs](#)

[The R Journal](#)

The R Project for Statistical Computing

Getting Started

R is a free software environment for statistical computing and graphics. It compiles and runs on a wide variety of UNIX platforms, Windows and MacOS. To [download R](#), please choose your preferred [CRAN mirror](#).

If you have questions about R like how to download and install the software, or what the license terms are, please read our [answers to frequently asked questions](#) before you send an email.

News

- [R version 3.4.0 \(You Stupid Darkness\) prerelease versions](#) will appear starting Tuesday 2017-03-21. Final release is scheduled for Friday 2017-04-21.
- [R version 3.3.3 \(Another Canoe\)](#) has been released on Monday 2017-03-06.
- [useR! 2017](#) (July 4 - 7 in Brussels) has opened registration and more at <http://user2017.brussels/>
- Tomas Kalibera has joined the R core team.
- The R Foundation welcomes five new ordinary members: Jennifer Bryan, Dianne Cook, Julie Josse, Tomas Kalibera, and Balasubramanian Narasimhan.
- [The R Journal Volume 8/1](#) is available.
- The [useR! 2017](#) conference will take place in Brussels, July 4 - 7, 2017.
- [R version 3.2.5 \(Very, Very Secure Dishes\)](#) has been released on 2016-04-14. This is a rebadging of the quick-fix release 3.2.4-revised.
- [Notice XQuartz users \(Mac OS X\)](#) A security issue has been detected with the Sparkle update mechanism used by XQuartz. Avoid updating over insecure channels.
- The [R Logo](#) is available for download in high-resolution PNG or SVG formats.
- [useR! 2016](#), has taken place at Stanford University, CA, USA, June 27 - June 30, 2016.

<https://www.r-project.org>

R的获取与安装

Step 1: 登录R语言官方网站<https://www.r-project.org>, 点击下载 R。



[Home]

Download

CRAN

R Project

About R

Logo

Contributors

What's New?

Mailing Lists

Reporting Bugs

Development Site

Conferences

Search

R Foundation

Foundation

Board

Members

Donors

Donate

The R Project for Statistical Computing

Getting Started

R is a free software environment for statistical computing and graphics. It compiles and runs on a wide variety of UNIX platforms, Windows and MacOS. To **download R**, please choose your preferred [CRAN mirror](#).

If you have questions about R like how to download and install the software, or what the license terms are, please read our [answers to frequently asked questions](#) before you send an email.

News

- The **useR!** 2017 conference will take place in Brussels, July 4 - 7, 2017, and details will be appear here in due course.
- **R version 3.3.1 (Bug in Your Hair)** has been released on Tuesday 2016-06-21.
- **R version 3.2.5 (Very, Very Secure Dishes)** has been released on 2016-04-14. This is a rebadging of the quick-fix release 3.2.4-revised.
- **Notice XQuartz users (Mac OS X)** A security issue has been detected with the Sparkle update mechanism used by XQuartz. Avoid updating over insecure channels.
- The **R Logo** is available for download in high-resolution PNG or SVG formats.

R的获取与安装

Step 2: 在弹出的镜像（Mirrors）页面上选择合适的镜像入口。

CRAN Mirrors

The Comprehensive R Archive Network is available at the following URLs, please choose a location close to you. Some statistics on the status of the mirrors can be found here: [main page](#), [windows release](#), [windows old release](#).

0-Cloud

<https://cloud.r-project.org/>

Automatic redirection to servers worldwide, currently sponsored by Rstudio

<http://cloud.r-project.org/>

Automatic redirection to servers worldwide, currently sponsored by Rstudio

Algeria

<https://cran.usthb.dz/>

University of Science and Technology Houari Boumediene

<http://cran.usthb.dz/>

University of Science and Technology Houari Boumediene

Argentina

<http://mirror.fcaglp.unlp.edu.ar/CRAN/>

Universidad Nacional de La Plata

Australia

<http://cran.csiro.au/>

CSIRO

<http://cran.ms.unimelb.edu.au/>

University of Melbourne

Austria

<https://cran.wu.ac.at/>

Wirtschaftsuniversität Wien

<http://cran.wu.ac.at/>

Wirtschaftsuniversität Wien

Belgium

<http://www.freestatistics.org/cran/>

K.U.Leuven Association

<https://lib.ugent.be/CRAN/>

Ghent University Library

<http://lib.ugent.be/CRAN/>

Ghent University Library

Brazil

<http://nbcqib.uesc.br/mirrors/cran/>

Center for Comp. Biol. at Universidade Estadual de Santa Cruz

<http://cran-r.c3sl.ufpr.br/>

Universidade Federal do Parana

<http://cran.fiocruz.br/>

Oswaldo Cruz Foundation, Rio de Janeiro

<https://vps.fmvz.usp.br/CRAN/>

University of Sao Paulo, Sao Paulo

<http://vps.fmvz.usp.br/CRAN/>

University of Sao Paulo, Sao Paulo

<http://brieger.esalq.usp.br/CRAN/>

University of Sao Paulo, Piracicaba

R的获取与安装

Step 2: 在弹出的镜像（Mirrors）页面上选择合适的镜像入口。

Chile	https://dirichlet.mat.puc.cl/ http://dirichlet.mat.puc.cl/	Pontificia Universidad Catolica de Chile, Santiago Pontificia Universidad Catolica de Chile, Santiago
China	https://mirrors.tuna.tsinghua.edu.cn/CRAN/ http://mirrors.tuna.tsinghua.edu.cn/CRAN/ http://mirrors.xmu.edu.cn/CRAN/	TUNA Team, Tsinghua University TUNA Team, Tsinghua University Xiamen University
Colombia	https://www.icesi.edu.co/CRAN/ http://www.icesi.edu.co/CRAN/	Icesi University Icesi University

如果你在中国，直接选择China下离你近的一个镜像即可。

R的获取与安装

Step 3: 选择镜像后就会跳转到下载页面，此时根据自己电脑的操作系统点击选择。



[CRAN](#)
[Mirrors](#)
[What's new?](#)
[Task Views](#)
[Search](#)

[About R](#)
[R Homepage](#)
[The R Journal](#)

[Software](#)
[R Sources](#)
[R Binaries](#)
[Packages](#)
[Other](#)

[Documentation](#)
[Manuals](#)
[FAQs](#)
[Contributed](#)

The Comprehensive R Archive Network

Download and Install R

Precompiled binary distributions of the base system and contributed packages, **Windows and Mac** users most likely want one of these versions of R:

- [Download R for Linux](#)
- [Download R for \(Mac\) OS X](#)
- [Download R for Windows](#)

R is part of many Linux distributions, you should check with your Linux package management system in addition to the link above.

Source Code for all Platforms

Windows and Mac users most likely want to download the precompiled binaries listed in the upper box, not the source code. The sources have to be compiled before you can use them. If you do not know what this means, you probably do not want to do it!

- The latest release (Tuesday 2016-06-21, Bug in Your Hair) [R-3.3.1.tar.gz](#), read [what's new](#) in the latest version.
- Sources of [R alpha and beta releases](#) (daily snapshots, created only in time periods before a planned release).
- Daily snapshots of current patched and development versions are [available here](#). Please read about [new features and bug fixes](#) before filing corresponding feature requests or bug reports.
- Source code of older versions of R is [available here](#).
- Contributed extension [packages](#)

Questions About R

- If you have questions about R like how to download and install the software, or what the license terms are, please read our [answers to frequently asked questions](#) before you send an email.

Windows系统下的安装



R for Windows

Subdirectories:

[base](#)

Binaries for base distribution. This is what you want to [install R for the first time](#).

[contrib](#)

Binaries of contributed CRAN packages (for R $\geq$ 2.13.x; managed by Uwe Ligges). There is also information on [third party software](#) available for CRAN Windows services and corresponding environment and make variables.

[old contrib](#)

Binaries of contributed CRAN packages for outdated versions of R (for R $<$ 2.13.x; managed by Uwe Ligges).

[Rtools](#)

Tools to build R and R packages. This is what you want to build your own packages on Windows, or to build R itself.

Please do not submit binaries to CRAN. Package developers might want to contact Uwe Ligges directly in case of questions / suggestions related to Windows binaries.

You may also want to read the [R FAQ](#) and [R for Windows FAQ](#).

Note: CRAN does some checks on these binaries for viruses, but cannot give guarantees. Use the normal precautions with downloaded executables.

[CRAN](#)
[Mirrors](#)
[What's new?](#)
[Task Views](#)
[Search](#)


[About R](#)
[R Homepage](#)
[The R Journal](#)

[Software](#)
[R Sources](#)
[R Binaries](#)
[Packages](#)
[Other](#)

[Documentation](#)
[Manuals](#)
[FAQs](#)

在安装阶段选base版本即可

Windows系统下的安装



Windows系统下的R界面

Mac OS X系统下的安装



R for Mac OS X

This directory contains binaries for a base distribution and packages to run on Mac OS X (release 10.6 and above). Mac OS 8.6 to 9.2 (and Mac OS X 10.1) are no longer supported but you can find the last supported release of R for these systems (which is R 1.7.1) [here](#). Releases for old Mac OS X systems (through Mac OS X 10.5) and PowerPC Macs can be found in the [old](#) directory.

Note: CRAN does not have Mac OS X systems and cannot check these binaries for viruses. Although we take precautions when assembling binaries, please use the normal precautions with downloaded executables.

As of 2016/03/01 package binaries for R versions older than 2.12.0 are only available from the [CRAN archive](#) so users of such versions should adjust the CRAN mirror setting accordingly.

R 3.6.0 "Planting of a Tree" released on 2019/04/26

Important: since R 3.4.0 release we are now providing binaries for OS X 10.11 (El Capitan) and higher using non-Apple toolkit to provide support for OpenMP and C++17 standard features. To compile packages you may have to download tools from the [tools](#) directory and read the corresponding note below.

Please check the MD5 checksum of the downloaded image to ensure that it has not been tampered with or corrupted during the mirroring process. For example type

```
md5 R-3.6.0.pkg
```

in the *Terminal* application to print the MD5 checksum for the R-3.6.0.pkg image. On Mac OS X 10.7 and later you can also validate the signature using

```
pkgutil --check-signature R-3.6.0.pkg
```

Latest release:

[R-3.6.0.pkg](#)

MD5-hash: 64ede92058dde6c4e4c2c11e0ba8a60c

SHA1-

hash: fe1ffed2c74322196db331fc1ec41fab3c40c385

(ca. 76MB)

R 3.6.0 binary for OS X 10.11 (El Capitan) and higher, signed package. Contains R 3.6.0 framework, R.app GUI 1.70 in 64-bit for Intel Macs, Tcl/Tk 8.6.6 X11 libraries and Texinfo 5.2. The latter two components are optional and can be omitted when choosing "custom install", they are only needed if you want to use the `tcltk` R package or build package documentation from sources.

CRAN

[Mirrors](#)

[What's new?](#)

[Task Views](#)

[Search](#)

About R

[R Homepage](#)

[The R Journal](#)

Software

[R Sources](#)

[R Binaries](#)

[Packages](#)

[Other](#)

Documentation

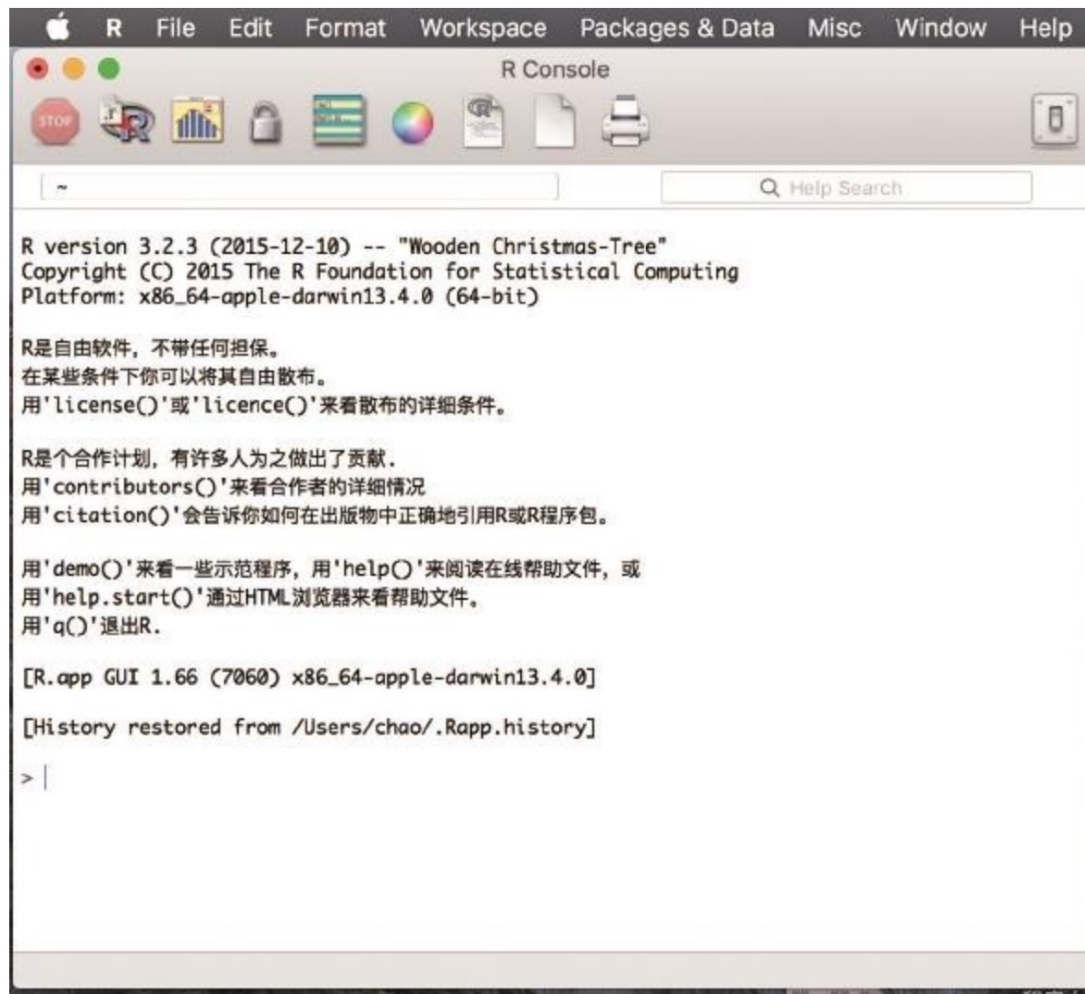
[Manuals](#)

[FAQs](#)

[Contributed](#)

下载pkg格式文件安装即可

Mac OS X系统下的安装



Mac OS X系统下的R界面

科普小知识

1. CRAN是什么？

它是[Comprehensive R Archive Network](#)的简写，是拥有同一资料包括R的发布版本、包、文档和源代码的网络集合。


2. 镜像CRAN Mirrors是什么？为什么要选择一个镜像？

镜像站就是把一个网站资源的[副本放在镜像服务器上](#)，也就是说登录不同的镜像网站都跟登录主网站一样。而选择一个离我们近的镜像主要是为了下载得快！


3. 上面提到的安装二进制版本，是唯一的安装方式吗？

不是，二进制是一种编译好的版本，不满足于基本配置并熟悉源代码安装的[也可以采用“源代码”安装方式](#)，当然这需要其他编译器，感兴趣的读者可以去谷歌搜索。

R GUI的升级版武器: RStudio



RStudio

[rstudio::conf](#)[Products](#)[Resources](#)[Pricing](#)[About Us](#)[Blogs](#)

Choose Your Version of RStudio


RStudio is a set of integrated tools designed to help you be more productive with R. It includes a console, syntax-highlighting editor that supports direct code execution, and a variety of robust tools for plotting, viewing history, debugging and managing your workspace. [Learn More about RStudio features.](#)

	RStudio Desktop Open Source License	RStudio Desktop Commercial License	RStudio Server Open Source License	RStudio Server Pro Commercial License
	FREE	\$995 per year	FREE	\$9,995 per year
Integrated Tools for R	●	●	●	●
Priority Support		●		●
Access via Web Browser			●	●
Enterprise Security				●
Project Sharing				●

<https://www.rstudio.com/products/rstudio/download/>

注意：R与RStudio的安装路径必须为英文！

RStudio




R还能干啥：清洗数据

理想中的数据分析师：




现实中的你：



实际项目中**80%**的时间
用于清洗数据!!!

R还能干啥：描述分析可视化



*Thank you for your
attentions !*
