

R语言基本介绍

王尧

西安交通大学智能决策与机器学习中心
(Email: yao.s.wang@gmail.com)

2024. 4

R参考小卡片

R Reference Card

by Tom Short, EPRI PEAC, tshort@epri-peac.com 2004-11-07

Granted to the public domain. See www.Rpad.org for the source and latest version. Includes material from *R for Beginners* by Emmanuel Paradis (with permission).

Getting help

Most R functions have online documentation.

help(topic) documentation on topic

?topic id.

help.search("topic") search the help system

apropos("topic") the names of all objects in the search list matching the regular expression "topic"

help.start() start the HTML version of help

str(a) display the internal *str*ucture of an R object

summary(a) gives a "summary" of a, usually a statistical summary but it is *generic* meaning it has different operations for different classes of a

ls() show objects in the search path; specify `pat="pat"` to search on a pattern

ls.str() str() for each variable in the search path

dir() show files in the current directory

methods(a) shows S3 methods of a

methods(class=class(a)) lists all the methods to handle objects of a class a

Input and output

load() load the datasets written with `save`

data(x) loads specified data sets

library(x) load add-on packages

read.table(file) reads a file in table format and creates a data frame from it; the default separator `sep=""` is any whitespace; use `header=TRUE` to read the first line as a header of column names; use `as.is=TRUE` to prevent character vectors from being converted to factors; use `comment.char=""` to prevent `"#"` from being interpreted as a comment; use `skip=n` to skip `n` lines before reading data; see the help for options on row naming, NA treatment, and others

read.csv("filename", header=TRUE) id. but with defaults set for

character or factor columns are surrounded by quotes (""); `sep` is the field separator; `eol` is the end-of-line separator; `na` is the string for missing values; use `col.names=NA` to add a blank column header to get the column headers aligned correctly for spreadsheet input

sink(file) output to file, until `sink()`

Most of the I/O functions have a `file` argument. This can often be a character string naming a file or a connection. `file=""` means the standard input or output. Connections can include files, pipes, zipped files, and R variables.

On windows, the file connection can also be used with `description = "clipboard"`. To read a table copied from Excel, use

```
x <- read.delim("clipboard")
```

To write a table to the clipboard for Excel, use

```
write.table(x, "clipboard", sep="\t", col.names=NA)
```

For database interaction, see packages RODBC, DBI, RMySQL, RPgSQL, and ROracle. See packages XML, hdf5, netCDF for reading other file formats.

Data creation

c(...) generic function to combine arguments with the default forming a vector; with `recursive=TRUE` descends through lists combining all elements into one vector

from:to generates a sequence; ":" has operator priority; `1:4+1` is "2,3,4,5"

seq(from,to) generates a sequence `by=` specifies increment; `length=` specifies desired length

seq(along=x) generates `1, 2, ..., length(along)`; useful for for loops

rep(x,times) replicate `x` times; use `each=` to repeat "each" element of `x` each times; `rep(c(1,2,3),2)` is `1 2 3 1 2 3`; `rep(c(1,2,3),each=2)` is `1 1 2 2 3 3`

data.frame(...) create a data frame of the named or unnamed arguments; `data.frame(v=1:4, ch=c("a", "B", "c", "d"), n=10)`; shorter vectors are recycled to the length of the longest

list(...) create a list of the named or unnamed arguments; `list(a=c(1,2), b="hi", c=3i)`;

array(x,dim=) array with data `x`; specify dimensions like `dim=c(3,4,2)`; elements of `x` recycle if `x` is not long enough

matrix(x,nrow=,ncol=) matrix; elements of `x` recycle

factor(x,levels=) encodes a vector `x` as a factor

gl(n,k,length=n*k,labels=1:n) generate levels (factors) by specifying the pattern of their levels; `k` is the number of levels, and `n` is the number of replications

expand.grid() a data frame from all combinations of the supplied vec-

Indexing lists

`x[n]` list with elements `n`
`x[[n]]` n^{th} element of the list
`x[["name"]]` element of the list named "name"
`x$name` id.

Indexing matrices

`x[i,j]` element at row `i`, column `j`
`x[i,]` row `i`
`x[,j]` column `j`
`x[,c(1,3)]` columns 1 and 3
`x["name",]` row named "name"

Indexing data frames (matrix indexing plus the following)

`x[["name"]]` column named "name"
`x$name` id.

Variable conversion

as.array(x), **as.data.frame(x)**, **as.numeric(x)**,
as.logical(x), **as.complex(x)**, **as.character(x)**,
... convert type; for a complete list, use `methods(as)`

Variable information

is.na(x), **is.null(x)**, **is.array(x)**, **is.data.frame(x)**,
is.numeric(x), **is.complex(x)**, **is.character(x)**,
... test for type; for a complete list, use `methods(is)`

length(x) number of elements in `x`

dim(x) Retrieve or set the dimension of an object; `dim(x) <- c(3,2)`

dimnames(x) Retrieve or set the dimension names of an object

nrow(x) number of rows; `NROW(x)` is the same but treats a vector as a one-row matrix

ncol(x) and **NCOL(x)** id. for columns

class(x) get or set the class of `x`; `class(x) <- "myclass"`

unclass(x) remove the class attribute of `x`

attr(x,which) get or set the attribute `which` of `x`

attributes(obj) get or set the list of attributes of `obj`

Data selection and manipulation

which.max(x) returns the index of the greatest element of `x`

which.min(x) returns the index of the smallest element of `x`

rev(x) reverses the elements of `x`

<https://cran.r-project.org/doc/contrib/Baggott-refcard-v2.pdf>

R中的数据类型

变量类型		变量名	详细说明	取值范围
影片部分	影片热度	boxoffice	上映三个月之内实现的票房（万元）	[924.9, 338 583.3]
	属性	doubanscore	豆瓣上对该电影的评分数据	[3.4, 8.0]
		type	影片类型	爱情、动作、犯罪、剧情、喜剧
		duration	电影放映时长（分钟）	[84, 131]
	档期	showtime	电影上映时期	[2016/2/8, 2016/5/6]
导演、演员部分	导演基本信息	director	导演名字	导演名字
	主演基本信息	star1	主演 1 的名字	演员名字
		index1	主演 1 在最近一个月的综合搜索指数	[178, 181 979]
		star2	主演 2 的名字	演员名字
		index2	主演 2 在最近一个月的综合搜索指数	[521, 77 260]

收集了2016年1—5月间上映的19部热门电影共10个变量的基本信息

R中的数据类型



2016年9月27日 星期二 加入协会 登录

首页 行业动态 影片档期 全国会员 全国影城 全国影院 数据中心 政策法规 电影设备 曝光台 申报中心 关于协会

票房周报排行榜

周影片排行

周影院排行

周影院排行

周地区排行

票房月报排行榜

月影院排行

月影院排行

月影片排行

票房月报国产影片排行

2016年4月

序号	名称	场次(千场)	人次(万人)	票房(万元)
1	火锅英雄	690.56	1,363.50	36,624.84
2	我的特工爷爷	578.76	1,016.91	32,009.37
3	北京遇上西雅图之不二情书	176.25	829.55	22,935.64
4	亲爱的，请靠近	331.00	590.80	15,581.57
5	睡在我上铺的兄弟	352.95	499.12	12,561.55
6	冰河追凶	190.99	170.05	4,262.14
7	梦想合伙人	78.70	149.95	3,576.39

火锅英雄 (2016)



导演: 杨庆

编剧: 杨庆

主演: 陈坤 / 白百何 / 秦昊 / 喻恩泰 / 王彦霖 /

更多...

类型: 剧情 / 犯罪

制片国家/地区: 中国大陆

语言: 汉语普通话 / 重庆话

上映日期: 2016-04-01(中国大陆)


片长: 95分钟

又名: 火锅 / Chongqing Hot Pot

IMDb链接: tt5596352

豆瓣评分

7.3 131545人评价



好于 60% 犯罪片
好于 42% 剧情片



数据来源于中国电影发行放映协会、豆瓣电影、百度指数等网站

R中的数据类型

name	boxoffice	doubanscore	type	duration	showtime	director	star1	index1	star2	index2
叶问3	77060.44	6.4	动作	105	2016/3/4	叶伟信	甄子丹	11385	张晋	4105
美人鱼	338583.3	6.9	喜剧	93	2016/2/8	周星驰	邓超	41310	林允	9292
女汉子真爱公式	6184.45	4.5	喜剧	93	2016/3/18	郭大雷	赵丽颖	181979	张翰	44277
西游记之孙悟空三打白骨精	119956.5	5.7	喜剧	120	2016/2/8	郑保瑞	郭富城	12227	巩俐	8546
澳门风云三	111693.9	4	喜剧	112	2016/2/8	王晶	周润发	16731	刘德华	30277
功夫熊猫3	99832.53	7.7	喜剧	95	2016/1/29	吕寅荣	杰克布莱克	178	安吉丽娜朱莉	1540
北京遇上西雅图之不二情书	78341.38	6.5	喜剧	131	2016/4/29	薛晓路	汤唯	13499	吴秀波	77260
谁的青春不迷茫	17798.89	6.4	爱情	108	2016/4/22	姚婷婷	白敬亭	14759	郭姝彤	755
睡在我上铺的兄弟	12561.55	5	爱情	95	2016/4/1	张琦	陈晓	13251	秦岚	9549
冰河追凶	4262.14	5.6	动作	102	2016/4/15	徐伟	梁家辉	6911	佟大为	5614
梦想合伙人	8058.15	3.8	剧情	101	2016/4/29	张太维	姚晨	7315	唐嫣	66756
我的新野蛮女友	3336.83	3.4	喜剧	107	2016/4/22	赵根植	宋茜	81163	车太贤	1789
刑警兄弟	3005.96	5.2	喜剧	97	2016/4/22	戚家基	黄宗泽	9823	金刚	4010

数据示例

```
rm(list = ls())
```

```
movie = read.csv("电影数据.csv", header = T, fileEncoding = "UTF-8")
```

注意：一定要把数据文件放在R当前的工作目录下(getwd()查看)

R中的数据类型

1. **数值型（numeric）**。数值型变量很简单，统计教材中的定量数据就是R中的数值型数据。比如数据集中的doubanscore, boxoffice等就是这类数据。当用符号“<-”或者“=”给一个变量赋予数字时，就默认生成数值型数据。

```
# 电影数据示例
class(movie$"boxoffice"); class(movie$doubanscore)
## [1] "numeric"
## [1] "numeric"
# 自己为变量赋一个数值
a = 2; class(a)
## [1] "numeric"
```

R中的数据类型

```
exp(1 000)
- 10/0
exp(1 000)/exp(990)
exp(10)
```

```
exp(1000) # 正无穷
## [1] Inf
-10 / 0 # 负无穷
## [1] -Inf
exp(1000) / exp(990) # NaN类型
## [1] NaN
exp(10)
## [1] 22026.47
```

数值型数据操作的实例

R中的数据类型

2. 字符型（**character**）。字符型变量从字面上很好理解，就是用来储存文字的，比如数据集中的**director**，**actor1**就是这种类型，然而未必都是如此。首先，不是文字的也可能是字符型，比如：

```
# 字符的定义
a = "2"
class(a)
## [1] "character"
```


R中的数据类型

2. 字符型（character）。字符型变量从字面上很好理解，就是用来储存文字的，比如数据集中的director，actor1就是这种类型，然而未必都是如此。首先，不是文字的也可能是字符型，比如：

```
# 字符的定义
a = "2"
class(a)
## [1] "character"
```

其次，文字也许并不是字符型。比如前面提到的电影数据集中，name，type等变量看起来都是文字，但如果导入R时不加特别设置，很可能会得到如下结果：

```
# 判断电影数据集中，变量 "type", "name" 是不是字符型变量
class(movie$type)
## [1] "factor"
class(movie$name)
## [1] "factor"
```

R中的数据类型

3. **逻辑型 (logical)**。逻辑型数据取值很有限，只有TRUE和FALSE两个值，它常常出现在各种条件设定语句中。逻辑型的结果还可以进行加减运算，原因就是TRUE在R中对应数字1，FALSE对应数字0。

```
movie$type[movie$name == "美人鱼"] == "喜剧"
## [1] TRUE
# 想在数据集中挑选大于7分的喜剧电影name?
movie$name[movie$type == "喜剧" & movie$"doubanscore" > 7]
## [1] "功夫熊猫3"
# 逻辑语句加减
(1 == 2) + (3 < 4)
## [1] 1
```

R中的数据类型

4. 因子型（factor）。

因子型数据通常用命令factor()来定义。

```
(genders = factor(c("男", "女", "女", "男", "男")))  
## [1] 男 女 女 男 男  
## Levels: 男 女
```

R中的数据类型

4. 因子型（factor）。

因子型数据通常用命令`factor()`来定义。因子型数据转换为字符型数据分为两步：第一步区分字符有几类，形成类型到整数的映射；第二步将原字符按照整数形式存储。

```
(genders = factor(c("男", "女", "女", "男", "男")))  
## [1] 男 女 女 男 男  
## Levels: 男 女
```

STEP I

建立字符“男”“女”与整数1, 2的映射关系, 具体地：男→1 & 女→2

STEP II

按照映射关系，将genders转换为整数存储，即c(1,2,2,1,1)。

R中的数据类型

4. 因子型 (factor)

因子型数据通常用命令 `factor()` 来定义。因子型数据转换为字符型数据分为两步：第一步区分字符有几类，形成类型到整数的映射；第二步将原字符按照整数形式存储。


有序型变量就是带有顺序的名义型变量，因此只需把 `factor()` 中的 `ordered` 参数设置好就可以了。

```
(class = factor(c("Poor", "Improved", "Excellent"), ordered = T,  
               levels = c("Poor", "Improved", "Excellent")))  
## [1] Poor      Improved  Excellent  
## Levels: Poor < Improved < Excellent
```

向量

向量是用于存储同一种类型数据的一维数组，是所有数据结构中最基础的形式。每个格子存储同种类型（比如，这里是字符型）的元素。


Vector



向量

向量是用于存储同一种类型数据的一维数组，是所有数据结构中最基础的形式。每个格子存储同种类型（比如，这里是字符型）的元素。

Vector



一般来说，采用函数`c()`即可完成向量的创建，只要在括号中输入每个向量元素即可。如果知道向量是以什么规律排列的，也可以按照规律生成向量。比如，创建的向量是等差数列的，就可以使用`seq()`函数；创建从`a`到`b`的连续整数，使用`a:b`就可实现。

```
c(1, 1, 1, 2, 3, 3, 1, 2, 4, 1, 2, 4, 4, 2, 3, 4, 1, 2, 3, 4)
## [1] 1 1 1 2 3 3 1 2 4 1 2 4 4 2 3 4 1 2 3 4
c("a", "b", "c", "d")
## [1] "a" "b" "c" "d"
# seq(起始值, 终止值, 步长)
seq(0, 10, by = 2)
## [1] 0 2 4 6 8 10
1:10
## [1] 1 2 3 4 5 6 7 8 9 10
```

向量的引用


```
# 引用x向量中的第5个元素
x=c(1, 1, 1, 2, 3, 3)
x[5]
## [1] 3
# 想看看x向量中3所在的位置
which(x == 3)
## [1] 5 6
which.max(x)
## [1] 5
which.min(x)
## [1] 1
```

向量常用操作函数

小函数	完成功能	使用方法
length	提取向量的长度	length(vector)
max	提取向量中的最大值	max(vector)
min	提取向量中的最小值	min(vector)
mean	提取向量的平均值	mean(vector)
median	提取向量的中位数	median(vector)
quantile	提取向量的分位数	quantile(vector, prob=seq(0,1,0.25))
sort	将向量重新排序	sort(vector)
rank	返回向量 x 的秩，即 x 中数字的大小顺序	rank(vector)
order	返回一个向量升序排序后的数字在原数据中的位置	order(vector)
match	在 y 中逐个查找 x ，并返回在 y 中匹配的位置，若无返回 NA	match(vector)
cut	将数值型数据分区间转换成因子型数据，即将数值型数据离散化	cut(x,breaks,label)

矩阵

R中，矩阵其实就是一个二维数组，外表类似Excel中的表格，但重点是其中的每个元素都必须具有相同的数据类型。矩阵也是在各种数值模拟运算中使用最多的数据结构。



矩阵

生成一个矩阵。生成一个矩阵很简单，使用`matrix( )`函数即可。

```
# 生成全部是0的矩阵
(zero = matrix(0, nrow = 3, ncol = 3))
##           [,1] [,2] [,3]
## [1,]      0   0   0
## [2,]      0   0   0
## [3,]      0   0   0
# 生成一个对角全是1的矩阵, 直接在diag中输入对角线向量即可
(dig = diag(rep(1, 4)))
##           [,1] [,2] [,3] [,4]
## [1,]      1   0   0   0
## [2,]      0   1   0   0
## [3,]      0   0   1   0
## [4,]      0   0   0   1
```

矩阵

把已有数据转换成矩阵类型。比如把向量转换成矩阵，通过以下代码就可以将向量1:12转换成3行4列的矩阵

```
# 从已有数据转化成矩阵
(M = matrix(1:12, nrow = 3, ncol = 4))
##           [, 1] [, 2] [, 3] [, 4]
## [1,]         1    4    7   10
## [2,]         2    5    8   11
## [3,]         3    6    9   12
```

基本的矩阵操作

```
# 查看矩阵的维度
dim(M)
## [1] 3 4
# 提取矩阵的行数
nrow(M)
## [1] 3
# 提取矩阵的列数
ncol(M)
## [1] 4
# 引用元素
M[1, 2]
## [1] 4
M[1:2, 2:3]
##      [,1] [,2]
## [1,]    4    7
## [2,]    5    8
# 给行列命名
colnames(M) = paste0("x_", 1:4)
rownames(M) = 1:3; M
##      x_1 x_2 x_3 x_4
## 1     1    4    7   10
## 2     2    5    8   11
## 3     3    6    9   12
# 同样的命令可调用行列名
colnames(M)
## [1] "x_1" "x_2" "x_3" "x_4"
rownames(M)
## [1] "1" "2" "3"
```


基本的矩阵操作

```
(A = matrix(1:9, nrow = 3, ncol = 3, byrow = T))
##           [,1] [,2] [,3]
## [1,]         1     2     3
## [2,]         4     5     6
## [3,]         7     8     9
(B = diag(11:13))
##           [,1] [,2] [,3]
## [1,]        11     0     0
## [2,]         0    12     0
## [3,]         0     0    13
rbind(A, B)
##           [,1] [,2] [,3]
## [1,]         1     2     3
## [2,]         4     5     6
## [3,]         7     8     9
## [4,]        11     0     0
## [5,]         0    12     0
## [6,]         0     0    13
cbind(A, B)
##           [,1] [,2] [,3] [,4] [,5] [,6]
## [1,]         1     2     3    11     0     0
## [2,]         4     5     6     0    12     0
## [3,]         7     8     9     0     0    13
```

矩阵合并

基本的矩阵操作

```
A + B
##          [,1] [,2] [,3]
## [1,]    12     2     3
## [2,]     4    17     6
## [3,]     7     8    22

A - B
##          [,1] [,2] [,3]
## [1,]    -10     2     3
## [2,]     4    -7     6
## [3,]     7     8    -4

A * B
##          [,1] [,2] [,3]
## [1,]    11     0     0
## [2,]     0    60     0
## [3,]     0     0   117

A %*% B
##          [,1] [,2] [,3]
## [1,]    11    24    39
## [2,]    44    60    78
## [3,]    77    96   117
```

矩阵的加减乘运算

矩阵常用数学操作函数

小函数	完成功能	使用方法
$+/ - / *$	对矩阵的各个元素完成加减乘运算	$A+B$; $A-B$; $A*B$
$\% * \%$	矩阵乘法	$A \% * \% B$
crossprod	矩阵 A 的转置与矩阵 B 的乘法	crossprod(A, B)
tcrossprod	矩阵 A 与矩阵 B 的转置的乘法	tcrossprod(A, B)
t	求矩阵 A 的转置	t(A)
solve	求矩阵 A 的逆	solve(A)
eigen	对矩阵进行特征值分解, 结果输出特征值及特征向量	eigen(A)
svd	对矩阵进行 svd 奇异值分解, 结果可输出矩阵 A 的奇异值及两个正交阵 U, V	svd(A)

数据框

1. 数据框(data.frame)是R中最常见的数据结构，一般来讲，从csv或txt文件读入时就会自动存储为数据框对象。不同于矩阵的是，比如，数值型与字符型数据不能同时存在于矩阵中，数据框支持多种数据类型。
2. 数据框的每一列必须是同一种数据类型。如果不符合规定，R会在一定范围内强制转换数据类型。

	name	boxoffice	doubanscore	type	duration	showtime	director	star1	index1	star2
1	叶问3	77060.44	6.4	动作	105	2016/3/4	叶伟信	甄子丹	11385	张晋
2	美人鱼	338583.26	6.9	喜剧	93	2016/2/8	周星驰	邓超	41310	林允
3	女汉子真爱公式	6184.45	4.5	喜剧	93	2016/3/18	郭大雷	赵丽颖	181979	张翰
4	西游记之孙悟空三打白骨精	119956.51	5.7	喜剧	120	2016/2/8	郑保瑞	郭富城	12227	巩俐
5	澳门风云三	111693.89	4.0	喜剧	112	2016/2/8	王晶	周润发	16731	刘德华
6	功夫熊猫3	99832.53	7.7	喜剧	95	2016/1/29	吕寅荣	杰克布莱克	178	安吉丽娜朱莉
7	北京遇上西雅图之不二情书	78341.38	6.5	喜剧	131	2016/4/29	薛晓路	汤唯	13499	吴秀波
8	谁的青春不迷茫	17798.89	6.4	爱情	108	2016/4/22	姚婷婷	白敬亭	14759	郭姝彤
9	睡在我上铺的兄弟	12561.55	5.0	爱情	95	2016/4/1	张琦	陈晓	13251	秦岚
10	冰河追凶	4262.14	5.6	动作	102	2016/4/15	徐伟	梁家辉	6911	佟大为

数据框的基本操作

1. 创建: `data.frame()` 就是专门构造数据框的函数, 语法是 `data.frame(col1, col2, col3)`, 即先定义好每列的向量, 然后组合成一个数据框即可。

```
# 读入一个txt,csv等格式数据,即自成一个数据框
```

```
movie = read.csv("电影数据.csv", fileEncoding = "UTF-8", stringsAsFactors = F)
```

```
class(movie)
```

```
## [1] "data.frame"
```

```
# 自己创建
```

```
star1 = c("邓超", "赵丽颖", "郭富城", "周润发", "杰克布莱克", "汤唯", "白敬亭", "陈晓", "梁家辉", "姚晨", "宋茜", "黄宗泽", "黄晓明")
```

```
birthyear = c(1979, 1987, 1965, 1955, 1969, 1979, 1993, 1987, 1958, 1979, 1987, 1980, 1977)
```

```
gender = c("男", "女", "男", "男", "男", "女", "男", "男", "男", "女", "女", "男", "男")
```

```
stars = data.frame(star1, birthyear, gender); head(stars)
```

```
##          star1 birthyear gender
```

```
## 1         邓超      1979      男
```

```
## 2        赵丽颖      1987      女
```

```
## 3         郭富城      1965      男
```

```
## 4         周润发      1955      男
```

```
## 5 杰克布莱克      1969      男
```

```
## 6          汤唯      1979      女
```

数据框的基本操作

2. 汇总：用函数`head()`提取数据前6行，就可以看到数据概貌；用函数`str()`来展示每列的数据类型，就可以确定是连续的数值还是离散的因子；如果不仅想看部分数据、了解数据类型，还想知道每列数据整体情况、整体的取值范围，这时就可以使用`summary()`。

```
head(movie)
##              name boxoffice doubanscore type duration  showtime
## 1          叶问3   77060.44         6.4 动作    105   2016/3/4
## 2          美人鱼 338583.26         6.9 喜剧     93   2016/2/8
## 3      女汉子真爱公式   6184.45         4.5 喜剧     93 2016/3/18
## 4 西游记之孙悟空三打白骨精 119956.51         5.7 喜剧    120 2016/2/8
## 5          澳门风云三 111693.89         4.0 喜剧    112 2016/2/8
## 6          功夫熊猫3  99832.53         7.7 喜剧     95 2016/1/29
##   director   star1 index1      star2 index2
## 1   叶伟信   甄子丹 11385      张晋   4105
## 2   周星驰     邓超 41310      林允   9292
## 3   郭大雷   赵丽颖 181979      张翰  44277
## 4   郑保瑞   郭富城 12227      巩俐   8546
## 5     王晶   周润发 16731      刘德华 30277
## 6 吕寅荣 杰克布莱克   178 安吉丽娜朱莉 1540
```

数据框的基本操作

2. 汇总：用函数`head( )`提取数据前6行，就可以看到数据概貌；用函数`str( )`来展示每列的数据类型，就可以确定是连续的数值还是离散的因子；如果不仅想看部分数据、了解数据类型，还想知道每列数据整体情况、整体的取值范围，这时就可以使用`summary( )`。

```
str(movie)
## 'data.frame': 19 obs. of 11 variables:
## $ name : chr "叶问3" "美人鱼" "女汉子真爱公式" "西游记之孙悟空三打白骨精" ...
## $ boxoffice : num 77060 338583 6184 119957 111694 ...
## $ doubanscore: num 6.4 6.9 4.5 5.7 4 7.7 6.5 6.4 5 5.6 ...
## $ type : chr "动作" "喜剧" "喜剧" "喜剧" ...
## $ duration : int 105 93 93 120 112 95 131 108 95 102 ...
## $ showtime : chr "2016/3/4" "2016/2/8" "2016/3/18" "2016/2/8" ...
## $ director : chr "叶伟信" "周星驰" "郭大雷" "郑保瑞" ...
## $ star1 : chr "甄子丹" "邓超" "赵丽颖" "郭富城" ...
## $ index1 : int 11385 41310 181979 12227 16731 178 13499 14759 13251 6911 ...
## $ star2 : chr "张晋" "林允" "张翰" "巩俐" ...
## $ index2 : int 4105 9292 44277 8546 30277 1540 77260 755 9549 5614 ...
```


数据框的基本操作

2. 汇总：用函数`head( )`提取数据前6行，就可以看到数据概貌；用函数`str( )`来展示每列的数据类型，就可以确定是连续的数值还是离散的因子；如果不仅想看部分数据、了解数据类型，还想知道每列数据整体情况、整体的取值范围，这时就可以使用`summary( )`。

```
summary(movie)
##      name      boxoffice      doubanscore      type
## Length:19      Min.   :   924.9      Min.   :3.400      Length:19
## Class :character 1st Qu.: 3799.5      1st Qu.:4.600      Class :character
## Mode  :character Median : 12561.5      Median :5.300      Mode  :character
##                      Mean  : 50813.3      Mean   :5.568
##                      3rd Qu.: 77700.9      3rd Qu.:6.450
##                      Max.   :338583.3      Max.   :8.000
##      duration      showtime      director      star1
## Min.   : 84.0      Length:19      Length:19      Length:19
## 1st Qu.: 94.5      Class :character  Class :character  Class :character
## Median : 99.0      Mode  :character  Mode  :character  Mode  :character
## Mean    :101.5
## 3rd Qu.:107.5
## Max.    :131.0
##      index1      star2      index2
## Min.   :   178      Length:19      Min.   :   521
## 1st Qu.: 8232      Class :character 1st Qu.: 3650
## Median : 12227      Mode  :character Median : 9292
## Mean    : 27861
## 3rd Qu.: 24663
## Max.    :181979
##                      Mean    :17369
##                      3rd Qu.:20763
##                      Max.    :77260
```

数据框的基本操作

3. 筛选引用：基本的引用语法与矩阵类似，使用 `A[i, j]` 就可以提取出 `A` 中第 `i` 行第 `j` 个元素，即通过行列号来引用。筛选分为选列和选行，选列很简单，通过符号 `$` 配列名即可实现（例如，用 `movie $ name` 可以提取出 `name` 这一列）；选行则一般通过行号，或者条件语句返回一个逻辑结果向量，而后 `R` 把其中为 `TRUE` 的行摘出来。

```
# 引用
movie[3, ] # 查看第3行的电影信息
##           name boxoffice doubanscore type duration  showtime director
## 3 女汉子真爱公式   6184.45         4.5 喜剧          93 2016/3/18  郭大雷
##      star1 index1 star2 index2 pre
## 3 赵丽颖 181979  张翰  44277   3
movie[, 8] # 查看第8列主演者的名字
## [1] "甄子丹"      "邓超"         "赵丽颖"       "郭富城"       "周润发"
## [6] "杰克布莱克"  "汤唯"         "白敬亭"       "陈晓"         "梁家辉"
## [11] "姚晨"        "宋茜"         "黄宗泽"       "黄晓明"       "洪金宝"
## [16] "陈坤"        "陶泽如"       "刘亦菲"       "何润东"
```

数据框的基本操作

3. 筛选引用：基本的引用语法与矩阵类似，使用A[i, j]就可以提取出A中第i行第j个元素，即通过行列号来引用。筛选分为选列和选行，选列很简单，通过符号\$配列名即可实现（例如，用movie \$ name可以提取出name这一列）；选行则一般通过行号，或者条件语句返回一个逻辑结果向量，而后R把其中为TRUE的行摘出来。

```
# 筛选
movie$star1 # 用$符号通过列名引用
## [1] "甄子丹" "邓超" "赵丽颖" "郭富城" "周润发"
## [6] "杰克布莱克" "汤唯" "白敬亭" "陈晓" "梁家辉"
## [11] "姚晨" "宋茜" "黄宗泽" "黄晓明" "洪金宝"
## [16] "陈坤" "陶泽如" "刘亦菲" "何润东"

(action = movie[movie$type == "动作", ]) # 选择数据中的动作电影
##      name boxoffice doubanscore type duration showtime director
## 1      叶问3  77060.44      6.4 动作    105  2016/3/4  叶伟信
## 10     冰河追凶  4262.14      5.6 动作    102  2016/4/15   徐伟
## 15  我的特工爷爷 32009.37      5.3 动作     99  2016/4/1   洪金宝
## 19      铜刀    924.86      4.3 动作     94  2016/5/20   阿甘

##      star1 index1 star2 index2 pre
## 1  甄子丹  11385  张晋   4105   1
## 10 梁家辉   6911 佟大为  5614  10
## 15 洪金宝   9148 刘德华  30277 15
## 19 何润东  11822 李学东   521   19

(action_long = movie[movie$type == "动作" & movie$duration > 100, ]) # 放映时间超过100分钟的动作电影
##      name boxoffice doubanscore type duration showtime director star1
## 1      叶问3  77060.44      6.4 动作    105  2016/3/4  叶伟信 甄子丹
## 10 冰河追凶  4262.14      5.6 动作    102  2016/4/15   徐伟 梁家辉

##      index1 star2 index2 pre
## 1  11385  张晋   4105   1
## 10  6911 佟大为  5614  10
```

数据框的基本操作

4. 排序：为了使数据框更加整齐有序，我们拿到数据后可能需要对它先进行排序工作。在R中可以按照下面的做法，其中`decreasing`参数用来设置是按升序还是降序排列。

```
# 按照票房降序排列
movie = movie[order(movie$boxoffice, decreasing = T), ]; head(movie)
##              name boxoffice doubanscore type duration  showtime
## 2          美人鱼 338583.26          6.9  喜剧          93  2016/2/8
## 4 西游记之孙悟空三打白骨精 119956.51          5.7  喜剧         120  2016/2/8
## 5          澳门风云三 111693.89          4.0  喜剧         112  2016/2/8
## 6          功夫熊猫3  99832.53          7.7  喜剧          95  2016/1/29
## 7 北京遇上西雅图之不二情书  78341.38          6.5  喜剧         131  2016/4/29
## 1              叶问3  77060.44          6.4  动作         105  2016/3/4
##   director    star1 index1      star2 index2 pre
## 2   周星驰    邓超  41310      林允  9292  2
```

数据框的基本操作

4. 排序：为了使数据框更加整齐有序，我们拿到数据后可能需要对它先进行排序工作。在R中可以按照下面的做法，其中`decreasing`参数用来设置是按升序还是降序排列。

```
# 先按电影类型排序，再按照豆瓣评分排序
movie = movie[order(movie$type, movie$doubanscore, decreasing = T), ]; head(movie)
##               name boxoffice doubanscore type duration  showtime
## 6      功夫熊猫3  99832.53          7.7 喜剧         95 2016/1/29
## 2      美人鱼 338583.26          6.9 喜剧         93 2016/2/8
## 7 北京遇上西雅图之不二情书 78341.38          6.5 喜剧        131 2016/4/29
## 4 西游记之孙悟空三打白骨精 119956.51          5.7 喜剧        120 2016/2/8
## 13      刑警兄弟   3005.96          5.2 喜剧         97 2016/4/22
## 3      女汉子真爱公式   6184.45          4.5 喜剧         93 2016/3/18
##   director      star1 index1      star2 index2 pre
## 6   吕寅荣 杰克布莱克   178 安吉丽娜朱莉  1540   6
## 2   周星驰      邓超  41310      林允   9292   2
## 7   薛晓路      汤唯  13499      吴秀波  77260   7
## 4   郑保瑞      郭富城 12227      巩俐   8546   4
## 13  戚家基      黄宗泽  9823      金刚   4010  13
## 3   郭大雷      赵丽颖 181979      张翰  44277   3
```


数据框的基本操作

6. 增列：实际中，我们拿到的原始数据可能并不满足需要，常常需要增加新列。R中的语法为 `dat $ column_name = vector`

```
prefer = 1:19
movie$pre = prefer
head(movie)
```

##		name	boxoffice	doubanscore	type	duration	showtime
## 1		叶问3	77060.44	6.4	动作	105	2016/3/4
## 2		美人鱼	338583.26	6.9	喜剧	93	2016/2/8
## 3		女汉子真爱公式	6184.45	4.5	喜剧	93	2016/3/18
## 4		西游记之孙悟空三打白骨精	119956.51	5.7	喜剧	120	2016/2/8
## 5		澳门风云3	111693.89	4.0	喜剧	112	2016/2/8
## 6		功夫熊猫3	99832.53	7.7	喜剧	95	2016/1/29

##	director	star1	index1	star2	index2	pre
## 1	叶伟信	甄子丹	11385	张晋	4105	1
## 2	周星驰	邓超	41310	林允	9292	2
## 3	郭大雷	赵丽颖	181979	张翰	44277	3
## 4	郑保瑞	郭富城	12227	巩俐	8546	4
## 5	王晶	周润发	16731	刘德华	30277	5
## 6	吕寅荣	杰克布莱克	178	安吉丽娜朱莉	1540	6

列表

5. 列表：列表可以容纳各种类型的数据对象，向量、矩阵、数据框，甚至一个列表也可以成为另一个列表的元素。



神奇的列表

列表的一些基本操作

```
(example = list("abc", 3:5, matrix(1, nrow = 3, ncol = 4), data.frame(x = 1:4, y = paste0("boy_", 1:4))))  
## [[1]]  
## [1] "abc"  
##  
## [[2]]  
## [1] 3 4 5  
##  
## [[3]]  
##      [,1] [,2] [,3] [,4]  
## [1,]  1   1   1   1  
## [2,]  1   1   1   1  
## [3,]  1   1   1   1  
##  
## [[4]]  
##    x    y  
## 1 1 boy_1  
## 2 2 boy_2  
## 3 3 boy_3  
## 4 4 boy_4
```

采用函数`list(a, b, c, d)`就可以把a, b, c, d四个对象组合成一个list对象

列表的一些基本操作

```
# 利用名字引用元素
complex$first
## [[1]]
## [1] 1 2
# 利用序号引用元素
complex[[1]]
## [[1]]
## [1] 1 2
```

两种引用元素操作

列表的一些基本操作

```
# 利用序号添加元素
complex[[3]] = matrix(1, 2, 3); complex

# 利用名字添加元素
complex$new = 1:5; complex

## $first
## $first[[1]]
## [1] 1 2
##
##
## $second
## $second[[1]]
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q"
## [18] "r" "s" "t" "u" "v" "w" "x" "y" "z"
##
## $second[[2]]
## $second[[2]][[1]]
##      [,1] [,2]
## [1,]    1    3
## [2,]    2    4
##
##
## [[3]]
##      [,1] [,2] [,3]
## [1,]    1    1    1
## [2,]    1    1    1
##
## $new
## [1] 1 2 3 4 5
```

两种添加元素操作

读入csv文件

csv的全称是comma separated values，它是一种用逗号分隔的文件，其跨平台支持性能很好，大部分的数据软件都可以对它直接处理。

```
name,boxoffice,doubanscore,type,duration,showtime,director,star1,index1,star2,index2
叶问3,77060.44,6.4,动作,105,2016/3/4,叶伟信,甄子丹,11385,张晋,4105
美人鱼,338583.26,6.9,喜剧,93,2016/2/8,周星驰,邓超,41310,林允,9292
女汉子真爱公式,6184.45,4.5,喜剧,93,2016/3/18,郭大雷,赵丽颖,181979,张翰,44277
西游记之孙悟空三打白骨精,119956.51,5.7,喜剧,120,2016/2/8,郑保瑞,郭富城,12227,巩俐,8546
澳门风云三,111693.89,4.0,喜剧,112,2016/2/8,王晶,周润发,16731,刘德华,30277
功夫熊猫3,99832.53,7.7,喜剧,95,2016/1/29,吕寅荣,杰克布莱克,178,安吉丽娜朱莉,1540
北京遇上西雅图之不二情书,78341.38,6.5,喜剧,131,2016/4/29,薛晓路,汤唯,13499,吴秀波,77260
谁的青春不迷茫,17798.89,6.4,爱情,108,2016/4/22,姚婷婷,白敬亭,14759,郭姝彤,755
睡在我上铺的兄弟,12561.55,5.0,爱情,95,2016/4/1,张琦,陈晓,13251,秦岚,9549
冰河追凶,4262.14,5.6,动作,102,2016/4/15,徐伟,梁家辉,6911,佟大为,5614
梦想合伙人,8058.15,3.8,剧情,101,2016/4/29,张太维,姚晨,7315,唐嫣,66756
我的新野蛮女友,3336.83,3.4,喜剧,107,2016/4/22,赵根植,宋茜,81163,车太贤,1789
刑警兄弟,3005.96,5.2,喜剧,97,2016/4/22,戚家基,黄宗泽,9823,金刚,4010
大唐玄奘,3271.44,5.1,剧情,90,2016/4/29,霍建起,黄晓明,32595,徐峥,10318
我的特工爷爷,32009.37,5.3,动作,99,2016/4/1,洪金宝,洪金宝,9148,刘德华,30277
火锅英雄,36624.84,7.3,犯罪,95,2016/4/1,杨庆,陈坤,5763,白百何,10585
百鸟朝凤,8686.14,8.0,剧情,108,2016/5/6,吴天明,陶泽如,1139,李岷城,3290
夜孔雀,3260.42,4.7,爱情,84,2016/5/20,戴思杰,刘亦菲,58355,刘烨,11248
钢刀,924.86,4.3,动作,94,2016/5/20,阿甘,何润东,11822,李学东,521
```

读入csv文件

csv的全称是**comma separated values**，它是一种用逗号分隔的文件，其跨平台支持性能很好，大部分的数据软件都可以对它直接处理。R中自带读取函数**read.csv()**。

```
movie_csv = read.csv("电影数据.csv", fileEncoding = "UTF-8"); head(movie_csv)
```

		name	boxoffice	doubanscore	type	duration	showtime
##	1	叶问3	77060.44	6.4	动作	105	2016/3/4
##	2	美人鱼	338583.26	6.9	喜剧	93	2016/2/8
##	3	女汉子真爱公式	6184.45	4.5	喜剧	93	2016/3/18
##	4	西游记之孙悟空三打白骨精	119956.51	5.7	喜剧	120	2016/2/8
##	5	澳门风云三	111693.89	4.0	喜剧	112	2016/2/8
##	6	功夫熊猫3	99832.53	7.7	喜剧	95	2016/1/29

	director	star1	index1	star2	index2
##	1	叶伟信	甄子丹	11385	张晋 4105
##	2	周星驰	邓超	41310	林允 9292
##	3	郭大雷	赵丽颖	181979	张翰 44277
##	4	郑保瑞	郭富城	12227	巩俐 8546
##	5	王晶	周润发	16731	刘德华 30277
##	6	吕寅荣	杰克布莱克	178	安吉丽娜朱莉 1540

读入xls (xlsx) 文件

xls (xlsx) 是Excel中的“原生态”表格数据格式。这可能是R初学者最关注的形式。但在R里我们并不经常直接读取xls (xlsx) 文件，因为在基础base包里没有可以对它直接处理的函数，并且xls (xlsx) 这种数据格式并不如csv的跨平台兼容性好。推荐的做法是将其另存为csv格式。

Hadley Wickham于2016年发布了一个读取Excel数据的新包[readxl](#)。

```
library("readxl")
# 其中col_names参数仍然是为了设定是否把第一行当做变量名
movie_excel = data.frame(read_excel("电影数据.xlsx", col_names = T)); head(movie_excel)
```

##		name	boxoffice	doubanscore	type	duration	showtime
## 1		叶问3	77060.44	6.4	动作	105	2016/3/4
## 2		美人鱼	338583.26	6.9	喜剧	93	2016/2/8
## 3		女汉子真爱公式	6184.45	4.5	喜剧	93	2016/3/18
## 4		西游记之孙悟空三打白骨精	119956.51	5.7	喜剧	120	2016/2/8
## 5		澳门风云3	111693.89	4.0	喜剧	112	2016/2/8
## 6		功夫熊猫3	99832.53	7.7	喜剧	95	2016/1/29

##	director	star1	index1	star2	index2
## 1	叶伟信	甄子丹	11385	张晋	4105
## 2	周星驰	邓超	41310	林允	9292
## 3	郭大雷	赵丽颖	181979	张翰	44277
## 4	郑保瑞	郭富城	12227	巩俐	8546
## 5	王晶	周润发	16731	刘德华	30277
## 6	吕寅荣	杰克布莱克	178	安吉丽娜朱莉	1540

readLines()读入数据

这份微博数据有8个指标：脱敏的微博名、所在地、性别、粉丝数、关注人数、微博数、创建时间以及个人描述。

weibo.txt											
熊粉1	北京 朝阳区	f	371068	183	2862	Wed Nov 24 15:54:44 +0800 2010	职业占星师，占星专栏作者，心理学、神秘学探索者。				
熊粉2	甘肃 白银	m	7	314	2	Fri Oct 07 16:42:39 +0800 2011					
熊粉3	海外 英国	f	686	600	1089	Sun Apr 18 22:12:07 +0800 2010					
熊粉4	上海 杨浦区	f	728201	202	11	Mon Aug 31 15:38:13 +0800 2009	日常更新在微信：znxmyzn 工作联系： 助理余小姐				
熊粉5	北京 东城区	f	508	336	536	Mon Mar 22 22:54:18 +0800 2010	愤青 宝妈 白领 普通青年 伪小资				
熊粉6	上海	m	577	499	698	Thu May 06 00:42:56 +0800 2010					
熊粉7	其他	f	147	2000	1272	Thu Nov 01 21:24:44 +0800 2012					
熊粉8	浙江 杭州	m	2189	15	48	Mon Feb 06 11:02:23 +0800 2012	淘宝商城 tmall 天猫 数据挖掘 数据分析				
熊粉9	上海	m	272	307	2403	Thu May 05 16:30:54 +0800 2011	极目楚天舒				
熊粉10	海外 其他	f	17887	2	705	Sun Dec 12 16:29:40 +0800 2010	一个飘在江湖的带刀女人。				
熊粉11	其他	m	1203	1344	709	Sun Apr 18 14:39:01 +0800 2010					
熊粉12	北京 海淀区	f	480	289	2779	Mon Jan 10 15:53:43 +0800 2011	座右铭：永远的真诚！ 最爱巧克力和奶酪				
熊粉13	北京	f	2889	529	1293	Sat Mar 05 15:26:20 +0800 2011					
熊粉14	北京 海淀区	f	700238	154	5001	Wed Mar 02 16:33:53 +0800 2011	清华园的网络茶楼，每天抛出几个话题，供来客茶余饭后品评				
熊粉15	北京 海淀区	m	747165	1312	18463	Mon Aug 23 16:26:13 +0800 2010	不做公知，做学问。微博言论欢迎媒体转发，不必征求本博主同意				
熊粉16	北京 东城区	m	807	797	3620	Sat Apr 24 21:25:20 +0800 2010					

readLines()读入数据

```
# weibo1是个字符向量
weibo1 = readLines("weibo.txt", encoding = "UTF-8")
head(weibo1)
## [1] "熊粉1 \t北京 朝阳区 \tf \t371068 \t183 \t2862 \tWed Nov 24 15:54:44 +0800 2010 \t职业占星师, 占星专栏作者, 心理学、神秘学探索者。"
## [2] "熊粉2 \t甘肃 白银 \tm \t7 \t314 \t2 \tFri Oct 07 16:42:39 +0800 2011 \t"
## [3] "熊粉3 \t海外 英国 \tf \t686 \t600 \t1089 \tSun Apr 18 22:12:07 +0800 2010 \t"
## [4] "熊粉4 \t上海 杨浦区 \tf \t728201 \t202 \t11 \tMon Aug 31 15:38:13 +0800 2009 \t日常更新在微信: znxmyzn 工作联系: 助理余小姐"
## [5] "熊粉5 \t北京 东城区 \tf \t508 \t336 \t536 \tMon Mar 22 22:54:18 +0800 2010 \t愤青 宝妈 白领 普通青年 伪小资"
## [6] "熊粉6 \t上海 \tm \t577 \t499 \t698 \tThu May 06 00:42:56 +0800 2010 \t"
```

readLines()必需参数只有一个文件名, 即可实现将文本按行读入, 对数据格式要求很低。

readLines()读入数据

```
# 使用字符分割函数将weibo1分开
tmp = strsplit(weibo1, " \\t")
class(tmp)
## [1] "list"
tmp[1:2]
## [[1]]
## [1] "熊粉1"
## [2] "北京 朝阳区"
## [3] "f"
## [4] "371068"
## [5] "183"
## [6] "2862"
## [7] "Wed Nov 24 15:54:44 +0800 2010"
## [8] "职业占星师, 占星专栏作者, 心理学、神秘学探索者。"
##
## [[2]]
## [1] "熊粉2" "甘肃 白银"
## [3] "m" "7"
## [5] "314" "2"
## [7] "Fri Oct 07 16:42:39 +0800 2011"
```

`strsplit(x, split)`可实现根据`split`将`x`分割, 最终分隔结果以列表形式输出


readLines()读入数据

```
# 查出每个list的元素的长度，来查看异常值
ll = sapply(tmp, length)
# 长度为0和1是异常行，长度为7和8的可以采用
table(ll)
##    ll
##    0  1  7  8
##    2  3 26 74
```

长度为0，即对应空行；有的长度为1，即对应一个空格以及一个异常字符；长度为7的是缺少最后一列描述的行；长度为8的是正常行。因此，在长度为7的行后填补一个空格，就能与长度为8的行合并成一个规整的数据框(课后练习)。

name	location	gender	Nfollowers	Nfollow	Nweibo	createTime	description
熊粉1	北京 朝阳区	f	371068	183	2862	Wed Nov 24 15:54:44 +0800 2010	职业占星师，占星专栏作者，心理学、神秘学探索者。
熊粉2	甘肃 白银	m	7	314	2	Fri Oct 07 16:42:39 +0800 2011	
熊粉3	海外 英国	f	686	600	1089	Sun Apr 18 22:12:07 +0800 2010	
熊粉4	上海 杨浦区	f	728201	202	11	Mon Aug 31 15:38:13 +0800 2009	日常更新在微信: znxmyzn 工作联系: 助理余小姐
熊粉5	北京 东城区	f	508	336	536	Mon Mar 22 22:54:18 +0800 2010	愤青 宝妈 白领 普通青年 伪小资
熊粉6	上海	m	577	499	698	Thu May 06 00:42:56 +0800 2010	
熊粉7	其他	f	147	2000	1272	Thu Nov 01 21:24:44 +0800 2012	

R包的获取与安装




The screenshot shows the RStudio interface with the 'Packages' tab selected. The 'System Library' section is expanded, displaying a list of installed and available packages. The table has columns for Name, Description, and Version. Checkmarks in the first column indicate installed packages.

Files Plots Packages Help Viewer			
Install Update			
	Name	Description	Version
System Library			
☐	boot	Bootstrap Functions (Originally by Angelo Canty for S)	1.3-20
☐	class	Functions for Classification	7.3-14
☐	cluster	"Finding Groups in Data": Cluster Analysis Extended Rousseeuw et al.	2.0.7-1
☐	codetools	Code Analysis Tools for R	0.2-15
☐	compiler	The R Compiler Package	3.5.1
☒	datasets	The R Datasets Package	3.5.1
☐	foreign	Read Data Stored by 'Minitab', 'S', 'SAS', 'SPSS', 'Stata', 'Systat', 'Weka', 'dBase', ...	0.8-70
☒	graphics	The R Graphics Package	3.5.1
☒	grDevices	The R Graphics Devices and Support for Colours and Fonts	3.5.1
☐	grid	The Grid Graphics Package	3.5.1
☐	KernSmooth	Functions for Kernel Smoothing Supporting Wand & Jones (1995)	2.23-15
☐	lattice	Trellis Graphics for R	0.20-35
☒	MASS	Support Functions and Datasets for Venables and Ripley's MASS	7.3-50
☒	Matrix	Sparse and Dense Matrix Classes and Methods	1.2-14
☒	methods	Formal Methods and Classes	3.5.1

R包是一个把R函数、数据、预编译代码以一种定义完善的格式组织在一起的集合。


R包的获取与安装



Name	Description	Version
System Library		
☐ boot	Bootstrap Functions (Originally by Angelo Canty for S)	1.3-20
☐ class	Functions for Classification	7.3-14
☐ cluster	"Finding Groups in Data": Cluster Analysis Extended Rousseeuw et al.	2.0.7-1
☐ codetools	Code Analysis Tools for R	0.2-15
☐ compiler	The R Compiler Package	3.5.1
☒ datasets	The R Datasets Package	3.5.1
☐ foreign	Read Data Stored by 'Minitab', 'S', 'SAS', 'SPSS', 'Stata', 'Systat', 'Weka', 'dBase', ...	0.8-70
☒ graphics	The R Graphics Package	3.5.1
☒ grDevices	The R Graphics Devices and Support for Colours and Fonts	3.5.1
☐ grid	The Grid Graphics Package	3.5.1
☐ KernSmooth	Functions for Kernel Smoothing Supporting Wand & Jones (1995)	2.23-15
☐ lattice	Trellis Graphics for R	0.20-35
☒ MASS	Support Functions and Datasets for Venables and Ripley's MASS	7.3-50
☒ Matrix	Sparse and Dense Matrix Classes and Methods	1.2-14
☒ methods	Formal Methods and Classes	3.5.1


R包是一个把R函数、数据、预编译代码以一种定义完善的格式组织在一起的集合。

R包的获取与安装




点击“Tools→Global Options”，打开Options界面更换下载镜像。

R包的获取与安装



直接通过CRAN服务器安装

R包的获取与安装



Personal Open source Business Explore Pricing Blog Support This repository Search Sign in Sign up

gaborcsardi / praise Watch 6 Star 52 Fork 47

<> Code Issues 4 Pull requests 0 Pulse Graphs

Praise useRs when they have done something good, or when they just need it

47 commits 1 branch 0 releases 21 contributors


Branch: master New pull request Find file Clone or download

gaborcsardi Oooops, missing smiley.R file Latest commit 968bb28 on Apr 18

R	Oooops, missing smiley.R file	3 months ago
inst	Add repo status badge to README	4 months ago
man	Roxygenize	3 months ago
tests	New "part of speech": smiley	3 months ago
.Rbuildignore	Ignore README.md and NEWS.md in /	a year ago
.gitignore	Initial commit of Mason template	a year ago
.travis.yml	User proper R Travis	4 months ago
DESCRIPTION	New "part of speech": smiley	3 months ago
LICENSE	Add superb words	a year ago
Makefile	Write README, move it to inst/ NEWS as well	a year ago

通过Github安装

R包的获取与安装



Personal Open source Business Explore Pricing Blog Support This repository Search Sign in Sign up

gaborcsardi / praise Watch 6 Star 52 Fork 47

<> Code Issues 4 Pull requests 0 Pulse Graphs

Praise useRs when they have done something good, or when they just need it

47 commits 1 branch 0 releases 21 contributors

Branch: master New pull request Find file Clone or download

		Latest commit 968bb28 on Apr 18
R	Oooops, missing smiley.R file	3 months ago
inst	Add repo status badge to README	4 months ago
man	Roxygenize	3 months ago
tests	New "part of speech": smiley	3 months ago
.Rbuildignore	Ignore README.md and NEWS.md in /	a year ago
.gitignore	Initial commit of Mason template	a year ago
.travis.yml	User proper R Travis	4 months ago
DESCRIPTION	New "part of speech": smiley	3 months ago
LICENSE	Add superb words	a year ago
Makefile	Write README, move it to inst/ NEWS as well	a year ago

```
library(devtools)
install_github("gaborcsardi/praise")
```

如何用好R包

CRAN Task Views

CRAN task views aim to provide some guidance which packages on CRAN are relevant for tasks related to a certain topic. They give a brief overview of the included packages and can be automatically installed using the [ctv](#) package. The views are intended to have a sharp focus so that it is sufficiently clear which packages should be included (or excluded) - and they are *not* meant to endorse the "best" packages for a given task.


- To automatically install the views, the [ctv](#) package needs to be installed, e.g., via
`install.packages("ctv")`
and then the views can be installed via `install.views` or `update.views` (where the latter only installs those packages are not installed and up-to-date), e.g.,
`ctv::install.views("Econometrics")`
`ctv::update.views("Econometrics")`
- The task views are maintained by volunteers. You can help them by suggesting packages that should be included in their task views. The contact e-mail addresses are listed on the individual task view pages.
- For general concerns regarding task views contact the [ctv](#) package maintainer.

Topics

Bayesian	Bayesian Inference
ChemPhys	Chemometrics and Computational Physics
ClinicalTrials	Clinical Trial Design, Monitoring, and Analysis
Cluster	Cluster Analysis & Finite Mixture Models
Databases	Databases with R
DifferentialEquations	Differential Equations
Distributions	Probability Distributions
Econometrics	Econometrics
Environmetrics	Analysis of Ecological and Environmental Data
ExperimentalDesign	Design of Experiments (DoE) & Analysis of Experimental Data
ExtremeValue	Extreme Value Analysis
Finance	Empirical Finance
FunctionalData	Functional Data Analysis
Genetics	Statistical Genetics
Graphics	Graphic Displays & Dynamic Graphics & Graphic Devices & Visualization
HighPerformanceComputing	High-Performance and Parallel Computing with R

寻找可用的包: <http://cran.r-project.org/web/views/>

如何用好R包



The screenshot shows the RStudio interface with the 'Viewer' pane open to the help documentation for the `glm` function. The search bar at the top right contains the text 'glm'. The documentation page has a title 'Fitting Generalized Linear Models' and a 'Description' section stating that `glm` is used to fit generalized linear models. The 'Usage' section shows the function signature and a call to `glm.fit`. The 'Arguments' section lists the `formula` argument.

Files Plots Packages Help Viewer

← → Home Print Copy

Search glm

R: Fitting Generalized Linear Models Find in Topic

glm {stats} R Documentation

Fitting Generalized Linear Models

Description

`glm` is used to fit generalized linear models, specified by giving a symbolic description of the linear predictor and a description of the error distribution.

Usage

```
glm(formula, family = gaussian, data, weights, subset,
    na.action, start = NULL, etastart, mustart, offset,
    control = list(...), model = TRUE, method = "glm.fit",
    x = FALSE, y = TRUE, singular.ok = TRUE, contrasts = NULL, ...)
```

```
glm.fit(x, y, weights = rep(1, nobs),
    start = NULL, etastart = NULL, mustart = NULL,
    offset = rep(0, nobs), family = gaussian(),
    control = list(), intercept = TRUE, singular.ok = TRUE)
```

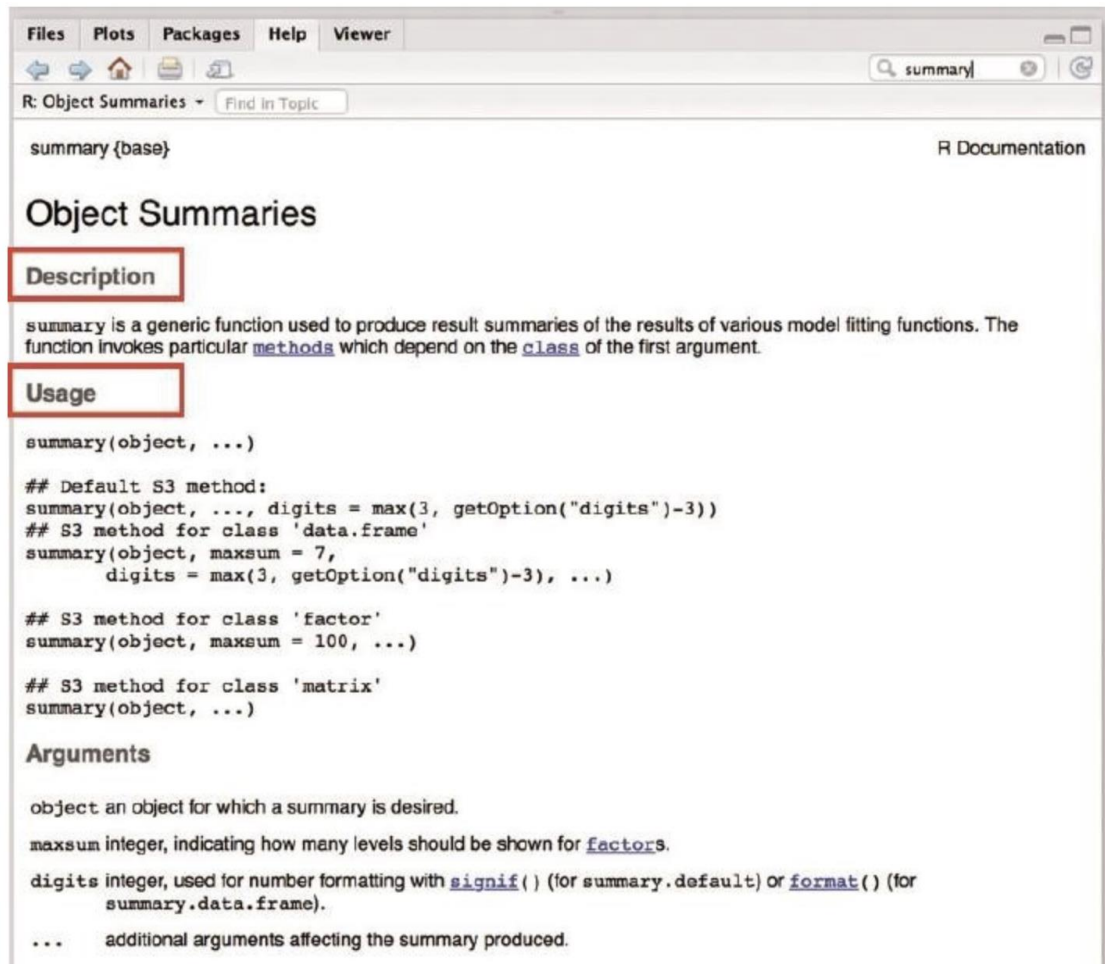
```
## S3 method for class 'glm'
weights(object, type = c("prior", "working"), ...)
```

Arguments

<code>formula</code>	an object of class " formula " (or one that can be coerced to that
----------------------	--

通过RStudio右下角界面的搜索框查看R包的帮助文档

如何用好R包



The screenshot shows the R Documentation window for the `summary` function. The window has a menu bar with 'Files', 'Plots', 'Packages', 'Help', and 'Viewer'. Below the menu bar is a search bar with 'summary' entered. The main content area is titled 'R: Object Summaries' and 'Find in Topic'. The 'Description' and 'Usage' sections are highlighted with red boxes. The 'Description' section explains that `summary` is a generic function used to produce result summaries of the results of various model fitting functions. The 'Usage' section shows the function signature and several S3 methods for different classes. The 'Arguments' section lists the parameters: `object`, `maxsum`, `digits`, and `...`.

summary {base} R Documentation

Object Summaries

Description

`summary` is a generic function used to produce result summaries of the results of various model fitting functions. The function invokes particular [methods](#) which depend on the [class](#) of the first argument.

Usage

```
summary(object, ...)
```

Default S3 method:
summary(object, ..., digits = max(3, getOption("digits")-3))
S3 method for class 'data.frame'
summary(object, maxsum = 7,
 digits = max(3, getOption("digits")-3), ...)

S3 method for class 'factor'
summary(object, maxsum = 100, ...)

S3 method for class 'matrix'
summary(object, ...)

Arguments

`object` an object for which a summary is desired.

`maxsum` integer, indicating how many levels should be shown for [factors](#).

`digits` integer, used for number formatting with [signif\(\)](#) (for `summary.default`) or [format\(\)](#) (for `summary.data.frame`).

`...` additional arguments affecting the summary produced.

首先阅读Description和Usage

如何用好R包

For `factors`, the frequency of the first `maxsum - 1` most frequent levels is shown, and the less frequent levels are summarized in "(Others)" (resulting in at most `maxsum` frequencies).

The functions `summary.lm` and `summary.glm` are examples of particular methods which summarize the results produced by `lm` and `glm`.

Value

The form of the value returned by `summary` depends on the class of its argument. See the documentation of the particular methods for details of what is produced by that method.

The default method returns an object of class `c("summaryDefault", "table")` which has a specialized print method. The `factor` method returns an integer vector.

The matrix and data frame methods return a matrix of class `"table"`, obtained by applying `summary` to each column and collating the results.

References

Chambers, J. M. and Hastie, T. J. (1992) *Statistical Models in S*. Wadsworth & Brooks/Cole.

See Also

[anova](#), [summary.glm](#), [summary.lm](#).

Examples

```
summary(attenu, digits = 4) #-> summary.data.frame(...), default precision
summary(attenu $ station, maxsum = 20) #-> summary.factor(...)
```

```
lst <- unclass(attenu$station) > 20 # logical with NAs
## summary.default() for logicals -- different from *.factor:
summary(lst)
summary(as.factor(lst))
```

进而查看帮助文档的Examples


如何用好R包

1. 使用demo()函数

输入demo()查看已经加载进内存的包里有例子的函数列表，输入demo(" function_name ")就可以执行某个具体函数的例子了。

2. 参考QuickGR网站


如果想看某些统计方法及数据操作的样例，网站QuickGR（<http://www.statmethods.net/index.html>）是个不错的选择。



如何用好R包

[About](#)[Products](#)[For Teams](#)[Home](#)[PUBLIC](#)[Questions](#)[Tags](#)[Users](#)[Companies](#)[COLLECTIVES](#)[Explore Collectives](#)[LABS](#)[Discussions](#)[TEAMS](#)

Stack Overflow for Teams – Start collaborating and sharing organizational knowledge.

[Create a free Team](#)[Why Teams?](#)

Questions tagged [glmnet]

[Ask Question](#)

glmnet is an R package for Lasso and elastic-net regularized generalized linear models.

[Learn more...](#) [Top users](#) [Synonyms](#)

603 questions

[Newest](#)[Active](#)[Bountied](#)[Unanswered](#)[More](#)[Filter](#)

0 votes

I get an error when I use the glmnet

0 answers

9 views

I get an error "[1] " >> STARTING ML RUN FOR RA_base__glmnet" Error in na.fail.default(list(Group = c("RA", "HC", "RA", NA, "RA", "RA",...

[R](#) [r](#) [glmnet](#)[rui sun](#) 1 asked yesterday

0 votes

confidence intervals of glmnet predictions?

0 answers

22 views

predict.lm has an option to return confidence intervals of predictions from lm models. Is there a way I can obtain the confidence intervals or SE of predictions from a glmnet model? library(glmnet)

[R](#) [r](#) [glmnet](#)[locus](#) 379 asked 2 days ago

0 votes

How can I train my data with lasso by performing a k-fold cross validation without the use of cv.glmnet function

0 answers

27 views

My dataset contains 33 predictors and 6216 observations. My goal is to compare different regression methods, in order to identify which has the best predictive performances, by collecting the...

[R](#) [r](#) [cross-validation](#) [glmnet](#) [lasso-regression](#) [mse](#)[ARaphs](#) 1 asked Oct 23 at 17:31

0 votes

Is it possible to calculate marginal effects on a ridge / lasso logistic regression model fit through glmnet?

1 answer

19 views

It seems like there is no support on applying the margins package to extract average marginal effects from a glmnet model. I am not able to replicate the same behaviour from glm as I'm fitting ...

课后要求

- 熟悉并掌握R语言的一些基本操作
- 理解R语言各类数据类型的特点
- 完成weibo数据的后续规整处理
- 针对自己需要处理的excel或csv文件，尝试用R语言完成课程类似的操作

*Thank you for your
attentions !*
