

爬虫简介

王尧

西安交通大学智能决策与机器学习中心
(Email: yao.s.wang@gmail.com)

2024. 5

前言

- 在数据科学与网络技术的各项技能中，人们对爬虫的兴趣远大于其他技能
- 通过爬虫收集数据是数据分析与挖掘极其重要的步骤
- R的爬虫生态不如Python
- 在熟悉R语言的基础上，结合已有的一些R软件包，可满足当前大部分的爬虫需求，特别是静态网页的爬取

爬虫的三个步骤

一个完整的爬虫过程可以简要地概括为“抓”“析”“存”三个阶段：

- 通过程序语言将目标网页抓取下载下来；
- 应用相关函数对网页进行解析并提取目标数据；
- 最后将数据存入本地数据库。

八爪鱼采集器 · 百万用户的选择

从海量数据中挖掘价值如此简单

免费下载

▶ 一分钟了解八爪鱼



零门槛三步获取数据

不懂网络爬虫技术，也可轻松采集数据

<https://www.bazhuayu.com>



八爪鱼Mac客户端下载

立即下载


软件版本: V8.6.2 更新日期: 2023年6月1日

 获取Windows版客户端



八爪鱼·大数据

让数据触手可及



云采集

5000台云服务器，API接口同步，定期采集数据



短信登录 密码登录

手机号

验证码

获取验证码

☐ 自动登录

登录/注册

未注册手机号验证后自动登录，注册即代表同意
《深圳数阅用户服务协议》

或



微信登录

您好h2dvgcl3，欢迎使用八爪鱼！

输入要采集的网站名称或网址 如：八爪鱼或www.bazhuayu.com

➔ 开始采集



什么是自定义任务

智能识别/操作引导，强大易用功能让您0代码自主灵活配置数据采集任务

+ 新建自定义任务

📺 查看讲解视频



什么是模板任务

聚合各行业数据模板，无需复杂配置快速采集海量数据，新老用户最爱

📺 去使用模板任务

📺 查看讲解视频

5.22-6.30

企业版用户
下单立减900元
另送华为Matepad!

新手演练

跟着小爪，手把手学习使用八爪鱼采集数据

开始演练

任务列表

热门模板

电子商务 本地生活 招投标 媒体阅读 社交平台

更多>

教程与帮助

更多>



微博搜索关键词采集

个人版 | 媒体阅读 | 🔒 102



链家新房详情（限云采集）

团队版 | 本地生活 | 🔒 119



京东商品评论

个人版 | 电子商务 | 🔒 148



百度搜索

个人版 | 搜索引擎 | 🔒 122



京东商品详情采集

个人版 | 电子商务 | 🔒 105



中国知网文献详情采集

个人版 | 科研教育 | 🔒 99



淘宝网-商品列表页采集

个人版 | 电子商务 | 🔒 108



百度地图坐标采集

个人版 | 搜索引擎 | 🔒 113



58同城招聘职位

个人版 | 本地生活 | 🔒 80



哔哩哔哩(B站b站)视频采集

个人版 | 媒体阅读 | 🔒 135



京东评论按分类-好中差评

个人版 | 电子商务 | 🔒 43



百度地图

团队版 | 搜索引擎 | 🔒 57



实例教程



图文教程



视频教程

【视频】自定义任务编辑界面介绍

【视频】入门-列表数据采集

【视频】入门-翻页以采集多页数据

【视频】入门-采集原理与执行逻辑

【图文】优化规则采集完整数据

【图文】 ajax网页采集方法

您好h2dvgcl3，欢迎使用八爪鱼！

输入要采集的网站名称或网址 如：八爪鱼或www.bazhuayu.com

→ 开始采集



什么是自定义任务

智能识别/操作引导，强大易用功能让您0代码自主灵活配置数据采集任务

+ 新建自定义任务

查看讲解视频



什么是模板任务

聚合各行业数据模板，无需复杂配置快速采集海量数据，新老用户最爱

去使用模板任务

查看讲解视频

5.22-6.30

企业版用户
下单立减900元
另送华为Matepad

新手演练

跟着小爪，手把手学习使用

开始演练

任务列表

免费试用

热门模板

电子商务

本地生活

招投标

媒体阅读

社交平台

更多>

教程与帮助



微博搜索关键词采集

个人版 | 媒体阅读 | 102



链家新房详情（限云采集）

团队版 | 本地生活 | 119



京东商品评论

个人版 | 电子商务 | 148



百度搜索



京东商品详情采集

个人版 | 电子商务 | 105



中国知网文献详情采集

个人版 | 科研教育 | 99



百度地图坐标采集

个人版 | 搜索引擎 | 113



58同城招聘职位

个人版 | 本地生活 | 80



京东评论按分类-好中差评

个人版 | 电子商务 | 43



百度地图

团队版 | 搜索引擎 | 57



实例教程



图文教程

【视频】自定义任务编辑

【视频】入门-列表数据

【视频】入门-翻页以采

【视频】入门-采集原理

【图文】优化规则采集完

【图文】ajax网页采集方

实战演练

退出演练

请复制下述演示采集网址并粘贴到输入框，开始演练的第一步：

https://demo.bazhuayu.com/

1/12

复制并粘贴



正在采集

等待3秒

重复数据: 0条 采集用时: 3秒 平均速度: 0条/分钟

|| 暂停

■ 停止

任务概况 数据列表 任务日志 采集历史

序号	标题	标题链接	时间	标题1	正文	字段
----	----	------	----	-----	----	----

实战演练

任务已启动开始自动采集列表和详情页数据，可选择“暂停”或“停止”任务；
采集完成后，选择合适的方式导出数据。八爪鱼支持导出为Excel、CSV、HTML或导出到数据库。

12/12

完成演练，等待数据导出

37

已采集到数据

正在采集

[点击列表链接] 加载网页中 ... https://demo.bazhuayu.com/37

重复数据: 0条 采集用时: 44秒 平均速度: 50条/分钟

暂停

停止

任务概况	数据列表	任务日志	采集历史			
序号	标题	标题链接	时间	标题1	正文	字段
7	新闻27: 解读泰山队现状, ...	https://demo.bazhuayu.co...	2022-08-05 16:43	27新闻内容详情	27新闻详情内容, 以下为示...	作者: keven
8	新闻28: 3年赚1.6亿! 皇马...	https://demo.bazhuayu.co...	2022-08-05 16:00	28新闻内容详情	28新闻详情内容, 以下为示...	作者: keven
9	新闻29: 英伟达Orin一旦“...	https://demo.bazhuayu.co...	2022-08-05 16:00	29新闻内容详情	29新闻详情内容, 以下为示...	作者: keven
10	新闻30: 元老“叛逃”, 经销...	https://demo.bazhuayu.co...	2022-08-05 16:00	30新闻内容详情	30新闻详情内容, 以下为示...	作者: keven
11	新闻31: 老教父造出硅谷新...	https://demo.bazhuayu.co...	2022-08-05 16:00	31新闻内容详情	31新闻详情内容, 以下为示...	作者: keven
12	新闻32: 过去10年, 谁是全...	https://demo.bazhuayu.co...	2022-08-05 16:43	32新闻内容详情	32新闻详情内容, 以下为示...	作者: keven
13	新闻33: 数据源盘点 230...	https://demo.bazhuayu.co...	2022-08-05 16:43	33新闻内容详情	33新闻详情内容, 以下为示...	作者: keven
14	新闻34: 贸易大顺差、人民...	https://demo.bazhuayu.co...	2022-08-05 16:00	34新闻内容详情	34新闻详情内容, 以下为示...	作者: keven
15	新闻35: 美方要求两家美国...	https://demo.bazhuayu.co...	2022-08-05 16:00	35新闻内容详情	35新闻详情内容, 以下为示...	作者: keven
16	新闻36: 市场监管总局: 疫...	https://demo.bazhuayu.co...	2022-08-05 16:00	36新闻内容详情	36新闻详情内容, 以下为示...	作者: keven
17	新闻37: 美方要求两家美国...	https://demo.bazhuayu.co...	2022-08-05 16:00			

50

已采集到数据

采集已完成

采集完成

重复数据：0条 采集用时：58秒 平均速度：51条/分钟

重新采集

导出数据

任务概况 数据列表 任务日志 采集历史

序号	标题	标题链接	采集时间	采集内容	采集详情	字段
1	新闻41：专家圈重点 胡伟...	https://demo.bazhuayu.co...	2022-08-05 16:00	46新闻内容详情	46新闻详情内容，以下为示...	作者：keven
2	新闻42：美方要求两家美国...	https://demo.bazhuayu.co...	2022-08-05 16:00	47新闻内容详情	47新闻详情内容，以下为示...	作者：keven
3	新闻43：解读泰山队现状， ...	https://demo.bazhuayu.co...	2022-08-05 16:43	48新闻内容详情	48新闻详情内容，以下为示...	作者：keven
4	新闻44：3年赚1.6亿！皇马...	https://demo.bazhuayu.co...	2022-08-05 16:43	49新闻内容详情	49新闻详情内容，以下为示...	作者：keven
5	新闻45：英伟达Orin一旦“...	https://demo.bazhuayu.co...	2022-08-05 16:43	50新闻内容详情	50新闻详情内容，以下为示...	作者：keven
6	新闻46：元老“叛逃”，经销...	https://demo.bazhuayu.co...	2022-08-05 16:00	46新闻内容详情	46新闻详情内容，以下为示...	作者：keven
7	新闻47：老教父造出硅谷新...	https://demo.bazhuayu.co...	2022-08-05 16:00	47新闻内容详情	47新闻详情内容，以下为示...	作者：keven
8	新闻48：过去10年，谁是全...	https://demo.bazhuayu.co...	2022-08-05 16:43	48新闻内容详情	48新闻详情内容，以下为示...	作者：keven
9	新闻49：老教父造出硅谷新...	https://demo.bazhuayu.co...	2022-08-05 16:00	49新闻内容详情	49新闻详情内容，以下为示...	作者：keven
10	新闻50：过去10年，谁是全...	https://demo.bazhuayu.co...	2022-08-05 16:43	50新闻内容详情	50新闻详情内容，以下为示...	作者：keven

采集完成!

任务 八爪鱼演示站点
用时 58秒
共采集数据 50 条 0 条重复
针对本次采集，说说你的感受!

稍后导出 导出数据



导出本地数据（八爪鱼演示站点）

导出文件类型

- ☒ Excel(xlsx) ☐ CSV文件 ☐ HTML文件 ☐ JSON
☐ Xml

导出到数据库

- ☐ SqlServer ☐ MySql

取消

确定

配置自动导出

导出到本地文件: 未配置 [去设置](#)

< > 文稿



强化学习



MATLAB



TencentMeeting



IMG_7852.PNG



八爪鱼演示站
点.csv



八爪鱼演示站
点.xlsx



58同城招聘职位

本地生活

采集58同城招聘板块的职位信息，支持自定义选择城市、职位。

个人版及以上
版本限制

采集方式

免费
云采集数据单价

无限制
每日上限

2023/01/03
模板更新时间

立即使用

收藏

赞 80

模板介绍

采集字段预览

采集参数预览

推荐

1. 点击【立即使用】进入参数配置界面。
2. 输入要搜索的网址，格式如：http://sz.58.com/cantfwy/?PGTID=0d202408-0000-4ee2-acfb-fd98aaebcc33&ClickID=1，每个网址之间用回车进行换行。
3. 输入需要采集的页数，即点击“下一页”的次数，请输入数字，如：5，10，15等，如果要采集全部，则不填写该参数，留空即可。
4. 所有参数设置完毕后，请点击【保存设置】，然后再点击【保存并启动采集】。

注意事项

- 模板在运行云采集之前，请用本地采集测试一下，是否可以正常采集数据，如果本地采集无法正常采集，请联系客服反馈。（采集过程请勿关闭界面，如有需要输入验证码，请快速手动输入验证码，保正常采集）
- 本地采集没问题时，进行云采集可能会出现防采集现象，导致云采集采集不到数据，可以通过重新启动几次云采集试试，或者在云采集详情里面通过重启相应子任务来试试，参考教程：bazhuayu.com/tutorial/ycjsk

采集数据预览

标题	职位	待遇	福利	招聘人数	学历	经验	城市	区县	地址	更新
包吃住+五险...	服务员		五险一金 包吃 ...	招3人	学历不限	经验不限	深圳	福田	深圳福田竹子...	今天

立即使用

收藏

赞 148



模板介绍

采集字段预览

采集参数预览

推广

使用方法

1. 点击【立即使用】进入参数配置界面。

2. 输入要采集的商品网址：`https://item.jd.com/100`

一系列网址进来。建议每个任务中的网址不要超过了1万个。

购买版本



模板任务

该模板任务仅限个人版及以上版本可用，您当前为免费版，升级套餐即可使用。

免费升级试用

马上升级



个人版

团队版

企业版

1个月

¥ 79

12个月

相当于按月63折

¥ 599

原价¥984

购买数量：

- 1 +

额外定制叠加方案 购买立即生效，有效期同版本时长一致

本地加速 (1个)

¥ 69/月

- 1 +

优惠卡券：

新注册礼券-个人版(月) ¥ 19



输入券码

余额抵扣：

¥ 0

账户余额 ¥ 0

全部抵扣

付款方式：



支付宝



微信支付



线下支付

应付金额

¥ 60

立即支付

教程与帮助

更多 >



实例教程



图文教程



视频教程

【视频】自定义任务编辑界面介绍

【视频】入门-列表数据采集

【视频】入门-翻页以采集多页数据

【视频】入门-采集原理与执行逻辑

【图文】优化规则采集完整数据

【图文】ajax网页采集方法

* 招聘页面网址

手动输入

文件导入

批量生成

请输入需要采集的58同城职位招聘页面的网址，如http://sz.58.com/cantfwy/?PGTID=0d202408-0000-4ee2-acfb-fd98aaebcc33&ClickID=1

* 采集页数

设置采集的前几页数据，默认10页，最多70页，如10,50等

任务名称

58同城招聘职位

任务组

My Group

新建任务组

▶ 启动采集

📁 保存任务



正在采集

等待7秒

重复数据: 0条 采集用时: 4分钟3秒 平均速度: 3条/分钟

暂停

停止

任务概况 数据列表 任务日志 采集历史

序号	标题	职位	待遇	福利	招聘人数	学历	经验	城市	区县
2	甜品店招学徒18-2...	服务员	4500-6800元/月	五险一金 包吃 包...	招8人	学历不限	经验不限,可接收应...	深圳	布吉
3	聘请服务员	服务员	4999-7999元/月	包吃 包住 年底双...	招11人	学历不限	经验不限	深圳	龙华
4	买车买房两月轻松...	KTV服务员	薪资面议	五险一金 包住 包吃	招若干人	学历不限	经验不限	深圳	龙华
5	蛋糕学徒可教18-2...	服务员	4500-6800元/月	五险一金 包吃 包住	招9人	学历不限	经验不限,可接收应...	深圳	布吉
6	看抖音不如学/视频...	销售助理/文员	薪资面议	求职保障 职业培训	招5人	高中	经验不限	深圳	福田
7	小白学电商运营+...	运营专员/助理	薪资面议	求职保障 职业培训	招5人	高中	经验不限	深圳	宝安
8	聘请服务员	服务员	4999-7999元/月	包吃 包住 年底双...	招11人	学历不限	经验不限	深圳	龙岗
9	礼仪/服装展示8k	酒吧服务员	7000-12000元/月	包住 包吃 五险一...	招9人	学历不限	经验不限	深圳	龙华
10	服务员2名	服务员	4000-5000元/月	包吃 包住 年底双...	招2人	学历不限	经验不限	深圳	南山
11	宴会厅服务员	服务员	4000-4500元/月	五险一金 包吃 包住	招2人	高中	1年以下	深圳	坪山
12	聘新人服务员包吃...	服务员	薪资面议	包住 包吃	招若干人	学历不限	经验不限	深圳	龙华

58同城招聘职位

3

< 返回

|| 暂停

正在打开 https://legoclick.58.com/jump?target=szq1XB3draOWUvYfXMKLuyOYpg-GUhl1pAbfPHEdPHm1n1EkrHNLrHR3sMPCiAd_TyEVujNOny7hrH0VPhELPzYYnyELsy7-mynV...

深圳 [切换城市 西安]

58APP

58首页

登录 / 注册

个人中心

商家中心

帮助中心

联系客服

网站导航

58同城·招聘

发布招聘

登记

深圳58同城 > 深圳服务业招聘 > 龙华服务业招聘 > 龙华服务业招聘

更新: 今天

浏览:341人

申请:11人

☆ 收藏

分享

举报

KTV服务员

薪资面议

买车买房两月轻松致富

荣成市伊恩酒吧

娱乐休闲/餐饮/服务

1-49人

企业招聘(已认证企业)

任务概况									
数据列表									
任务日志									
采集历史									
序号	标题	职位	待遇	福利	招聘人数	学历	经验	城市	区县
1	进厂太累来礼仪6k...	服务员	5000-6000元/月	五险一金 包住 包吃	招8人	学历不限	经验不限	深圳	龙岗
2	甜品店招学徒18-2...	服务员	4500-6800元/月	五险一金 包吃 包...	招8人	学历不限	经验不限,可接收应...	深圳	布吉
3	聘请服务员	服务员	4999-7999元/月	包吃 包住 年底双...	招11人	学历不限	经验不限	深圳	龙华

HTML简介

- HTML的全称是超文本标记语言（hyper text markup language），是一种用于在网页上展示内容的语言。
- HTML并不是一种编程语言，而是一种描述内容并定义其表征的标记语言。
- 从内容上看，HTML是标签、元素和属性的组合；从结构上看，HTML是一个树形组织结构

rvest包

静态网页，就是打开一个目标网页，在网页里可以直接看到想要抓取的数据，点击鼠标右键查看源代码后发现在HTML结构中可以原原本本地找到刚刚在网页里的目标数据。对于这样的网页，rvest可以提供一套较为完整的数据抓取方案，配上一些小工具，就可以快速实现爬虫。


芳华 (2017)



更新描述或海报

导演: 冯小刚
编剧: 严歌苓
主演: 黄轩 / 苗苗 / 钟楚曦 / 杨采钰 / 李晓峰 / 更多...
类型: 剧情 / 历史 / 战争
制片国家/地区: 中国大陆
语言: 汉语普通话
上映日期: 2017-12-15(中国大陆) / 2017-09-07(多伦多电影节)
片长: 136分钟 / 146分钟(多伦多电影节)
又名: 歌声离我远去 / Youth
IMDb链接: tt6654316

豆瓣评分
7.6 ★★★★★
694515人评价



好友评分
8.2 8人评价

好于 62% 历史片
好于 58% 战争片

在哪儿看这部电影 ·····

爱奇艺视频 免费观看
腾讯视频 免费观看
优酷视频 免费观看

豆瓣成员常用的标签 ·····

文艺 青春 人性 历史 战争
中国大陆 人生 剧情



精神分析大师弗洛伊德，心理学巨著合集现货发售
豆瓣书店

以下豆列推荐 ····· (全部)

豆瓣电影【口碑榜】2020-12-23 更新 (影志)

怪盗披头三【五星乱炖】(盗三)

评价人数超过十万的电影 (依然饭特稀)

云南映画志 (内陆飞鱼)

爱·感动 ((Claire)在想你)


我看过这部电影 2017-12-20 修改 删除

我的评价: ★★★★★ ☆推荐

写短评 写影评 + 添加到豆列 分享到

芳华的剧情简介 ·····

故事发生在上世纪七十年代，寄人篱下的少女何小萍（苗苗 饰）来到一所寄宿学校报到，邂逅了那里和她曾经待过的那些地方并无不同，她依然得忍受着冷眼和嘲笑。刘峰（黄轩 饰），不仅是对何小萍，被称为“活雷锋”的刘峰把自己全部的热情和真诚都倾注给了她，更是对所有人。实际上，刘峰一直爱慕着美丽活泼的林丁丁（杨采钰 饰）。人生走向了完全不同的方向。战争开始了，刘峰、何小萍和林丁丁三个人的生活命运都开始被战争改变。他们每个人都用生命和热血绽放着属于他们的芳华。 ©豆瓣



Save Page As...
Save Page to Pocket

Send Page to Device

View Background Image
Select All

View Page Source
View Page Info

Inspect Accessibility Properties
Inspect Element

Take a Screenshot

推荐

rvest包

静态网页，就是打开一个目标网页，在网页里可以直接看到想要抓取的数据，点击鼠标右键查看源代码后发现在HTML结构中可以原原本本地找到刚刚在网页里的目标数据。对于这样的网页，rvest可以提供一套较为完整的数据抓取方案，配上一些小工具，就可以快速实现爬虫。

The screenshot shows a web browser displaying the movie '芳华' (Fenghua) on the Douban website. The movie's poster is visible, along with its title '芳华 (2017)' and a rating of 7.6. The browser's developer tools are open, showing the HTML structure. The 'Inspector' tab is active, displaying the HTML code for the movie's details. The code includes a script tag for 'bundle.js' and a link tag for 'bundle.css'. The HTML structure is as follows:

```
<!DOCTYPE html>
<html class="ua-mac ua-ff84" lang="zh-CN">
  <head>
  </head>
  <body>
    <script type="text/javascript">var _body_start = new Date();</script>
    <link href="//img3.doubanio.com/dae/accounts/resources/d3e2921/shire/bundle.css" rel="stylesheet" type="text/css">
    <div id="db-global-nav" class="global-nav">
    </div>
    <script>
    </script>
    <script src="//img3.doubanio.com/dae/accounts/resources/d3e2921/shire/bundle.js" defer="defer">
    </script>
    <link href="//img3.doubanio.com/dae/accounts/resources/d3e2921/movie/bundle.css" rel="stylesheet" type="text/css">
    <div id="db-nav-movie" class="nav">
    </div>
    <script id="suggResult" type="text/x-jquery-tmpl">
    </script>
    <script src="//img3.doubanio.com/dae/accounts/resources/d3e2921/movie/bundle.js" defer="defer">
    </script>
    <div id="wrapper">
      <div id="content">
        <div id="dale_movie_subject_top_icon" ad-status="loaded">
        </div>
        <h1>
          <span property="v:itemreviewed">芳华</span>
          <span class="year">(2017)</span>
        </h1>
        <div class="grid-16-8 clearfix">
          <div class="article">
            <div class="indent clearfix">
            </div>
            <div id="collect_form_26862829">
            </div>
            <div class="related-info" style="margin-bottom:-10px;">
              <a name="intro"></a>
            </div>
          </div>
        </div>
      </div>
    </div>
  </body>
</html>
```

rvest包

静态网页，就是打开一个目标网页，在网页里可以直接看到想要抓取的数据，点击鼠标右键查看源代码后发现在HTML结构中可以原原本本地找到刚刚在网页里的目标数据。对于这样的网页，rvest可以提供一套较为完整的数据抓取方案，配上一些小工具，就可以快速实现爬虫。

read_html(): 下载并解析网页

html_nodes(): 定位并获取节点信息

html_text(): 提取节点属性文本信息

rvest的核心函数

XPath表达式

XPath表达式本质上是一种可以查询标记语言的方法。简单来说，XPath表达式就是选取HTML文件中节点的方法。这里的节点就是前面提到的HTML文档中的元素。

nodename: 选择该节点的所有子节点

“/”: 选择根节点

“//”: 选择任意节点

“@”: 选择属性

XPath表达式

芳华 (2017)

span 52 x 26.5

导演: 冯小刚
编剧: 严歌苓

Inspector Console Debugger Style Editor Performance Memory Network

+ Search HTML

```
<!DOCTYPE html>
<html class="ua-mac ua-ff67" lang="zh-cmn-Hans">
  <head>
  <body>
    <script type="text/javascript">var _body_start = new Date();</script>
    <link href="//img3.doubanio.com/dae/accounts/resources/ec819da/shire/bundle.css" rel="stylesheet"
    <div id="db-global-nav" class="global-nav">
    <script>
    <script src="//img3.doubanio.com/dae/accounts/resources/ec819da/shire/bundle.js" defer="defer">
    <link href="//img3.doubanio.com/dae/accounts/resources/ec819da/movie/bundle.css" rel="stylesheet"
    <div id="db-nav-movie" class="nav">
    <script id="suggResult" type="text/x-jquery-tmpl">
    <script src="//img3.doubanio.com/dae/accounts/resources/ec819da/movie/bundle.js" defer="defer">
    <div id="wrapper">
      <div id="content">
        <div id="dale_movie_subject_top_icon" ad-status="loaded">
          <h1>
            <span property="v:itemreviewed">芳华</span>
            <span class="year">(2017)</span>
```

XPath表达式

芳华 (2017)

span 52 x 26.5

导演: 冯小刚
编剧: 严歌苓

Inspector Console Debugger Style Editor Performance Memory Network

+ Search HTML

```
<!DOCTYPE html>
<html class="ua-mac ua-ff67" lang="zh-cmn-Hans">
  <head>
  <body>
    <script type="text/javascript">var _body_start = new Date();</script>
    <link href="//img3.doubanio.com/dae/accounts/resources/ec819da/shire/bundle.css" rel="stylesheet"
    <div id="db-global-nav" class="global-nav">
    <script>
    <script src="//img3.doubanio.com/dae/accounts/resources/ec819da/shire/bundle.js" defer="defer"></
    <link href="//img3.doubanio.com/dae/accounts/resources/ec819da/movie/bundle.css" rel="stylesheet"
    <div id="db-nav-movie" class="nav">
    <script id="suggResult" type="text/x-jquery-tmpl">
    <script src="//img3.doubanio.com/dae/accounts/resources/ec819da/movie/bundle.js" defer="defer"></
    <div id="wrapper">
      <div id="content">
        <div id="dale_movie_subject_top_icon" ad-status="loaded"></div>
      <h1>
        <span property="v:itemreviewed">芳华</span>
        <span class="year">(2017)</span>
      </h1>
    </div>
  </body>
</html>
```

```
library(rvest)
# install.packages(xml2)
library(xml2)
# install.packages(dplyr)
library(dplyr)
read_html('http://movie.douban.com/subject/26862829/') %>% html_nodes(xpath = "//h1//span")
## {xml_nodeset (2)}
## [1] <span property="v:itemreviewed">芳华</span>
## [2] <span class="year">(2017)</span>
```

自动生成XPath表达式

SelectorGadget是一款可以快速定位节点信息的插件，可以方便快捷地生成网页中想要提取的信息的XPath表达式。简单来说，就是能够“所见即所得”，得到的XPath信息可以直接复制到R爬虫代码中，方便快捷。

[All](#)[News](#)[Images](#)[Videos](#)[Maps](#)[More](#)[Settings](#)[Tools](#)

About 10,400 results (0.31 seconds)

SelectorGadget: point and click CSS selectors

<https://selectorgadget.com/> ▼

SelectorGadget is an open source tool that makes CSS selector generation and discovery on complicated sites a breeze. Just install the Chrome Extension or ...

SelectorGadget - Google Chrome

<https://chrome.google.com/.../selectorgadget/mhjhnkcfbdhjnjkckkdbjoemdmfginb?h...> ▼

Mar 20, 2015 - **Selector Gadget** is an open source Chrome Extension that makes CSS selector generation and discovery on complicated sites a breeze.

SelectorGadget - R Project

<https://cran.r-project.org/web/packages/rvest/vignettes/selectorgadget.html> ▼

May 15, 2019 - **SelectorGadget** is a JavaScript bookmarklet that allows you to interactively figure out what css selector you need to extract desired components ...

自动生成XPath表达式



chrome web store



yao.s.wang@gmail.com ▾

[Home](#) > [Extensions](#) > SelectorGadget



SelectorGadget

Offered by: [selectorgadget.com](#)

★★★★☆ 82 | [Developer Tools](#) | 👤 99,882 users

Add to Chrome

Overview

Reviews

Support

Related



自动生成XPath表达式



chrome.google.com/webstore/detail/selectorgadget/mhjhnkcfbdhnjickkkdbjoemdmfbginb?hl=en



chrome web store



yao.s.wang@gmail.com

[Home](#) > [Extensions](#) > SelectorGadget



SelectorGadget

Offered by: [selectorgadget.com](#)

★★★★★ 82

[Developer Tools](#)

99,882 users

Remove from Chrome

Overview

Reviews

Support

Related

回到芳华



movie.douban.com says

The CSS selector 'h1' as an XPath is shown below. Please report any bugs that you find with this converter.

//h1

Cancel

OK



芳华 (2017)



导演: 冯小刚

编剧: 严歌苓

主演: 黄轩 / 苗苗 / 钟楚曦 / 杨采钰 / 李晓峰 / 更多...

类型: 剧情 / 历史 / 战争

制片国家/地区: 中国大陆

语言: 汉语普通话

上映日期: 2017-12-15(中国大陆) / 2017-09-07(多伦多电影节)


片长: 136分钟 / 146分钟(多伦多电影节)

又名: 歌声离我远去 / Youth

IMDb链接: [tt6654316](https://www.imdb.com/title/tt6654316)

豆瓣评分

7.6  694515人评价



好于 62% 历史片

好于 58% 战争片

在哪儿看这部电影 ·····

爱奇艺视频 免费观看

优酷视频 免费观看

腾讯视频 免费观看

豆瓣成员常用的标签 ·····

文艺 青春 人性 历史 战争

中国大陆 人生 剧情

想看 看过 评价: ☆☆☆☆☆

写短评 写影评 分享到

推荐

芳华的剧情简介 ·····

故事发生在上世纪七十年代，寄人篱下的少女何小萍（苗苗 饰）经过重重试炼终于加入了梦寐以求的文工团，哪知道这里和她曾经待过的那些地方并无不同，她依然得忍受遭人唾弃和欺侮的生活。唯一给过她温暖的，是刘峰（黄轩 饰），不仅仅是对何小萍，被称为“活雷锋”的刘峰把自己的爱情和温暖无私的奉献给每一个人。

实际上，刘峰一直爱慕着美丽活泼的林丁丁（杨采钰 饰），当他选择将这份感情勇敢的表达出来时，却让自己的人生走向了完全不同的方向。战争开始了，刘峰、何小萍和萧穗子前赴后继的走上了前线，在枪弹和炮火之中，每一个人都用生命和热血绽放着属于他们的芳华。 ©豆瓣

芳华的演职员 ····· (全部 33)

h1

Clear (1)

Toggle Position

XPath

?

X

回到芳华

```
library(xml2)
library(rvest)
library(dplyr)
read_html('http://movie.douban.com/subject/26862829/') %>% html_nodes(xpath = "//h1")
```

```
## {xml_node} (1)
## [1] <h1>\n      <span property="v:itemreviewed">芳华</span>\n      <spa ...
```

```
read_html('http://movie.douban.com/subject/26862829/') %>% html_nodes(xpath = "//h1") %>% html_text()
```

```
## [1] "\n      芳华\n      (2017)\n      "
```

数据爬虫具体流程

目标
网页

SelectorGadget



解析

点击相应位置



查看
结点
名称

R语言

Rvest 包



```
网址变量 = read_html(str_c("网址"), encoding = "UTF-8")
```

```
名称 = 网址变量 %>% html_nodes("结点名称") %>% html_text()
```

抓取实例

https://hz.lianjia.com/ershoufang/pg

默认排序

最新发布


房屋总价

房屋单价

房屋面积

☰ ☱

共找到 **59778** 套杭州二手房



复兴南苑，两居室，满五唯一，拎包入住... 必看好房

📍 复兴南苑 - 复兴

🏠 2室1厅 | 47.9平米 | 南 | 简装 | 低楼层(共7层) | 1998年建 | 板楼

☆ 1人关注 / 10天以前发布


近地铁

VR房源

随时看房

206 万

单价43007元/平米



云雀苑 2室1厅 279万 必看好房

📍 云雀苑 - 鼓楼

🏠 2室1厅 | 68.59平米 | 南 | 简装 | 低楼层(共6层) | 1995年建 | 板楼

☆ 1人关注 / 13天以前发布

近地铁

VR房源


随时看房

加入对比

关注

279 万

单价40677元/平米



精装一年，品牌家居带露台，拎包入住! 必看好房

📍 山南人家 - 复兴

🏠 2室1厅 | 59.68平米 | 南 | 精装 | 高楼层(共6层) | 2010年建 | 板楼

☆ 21人关注 / 8天以前发布

近地铁

VR房源

250 万

单价41891元/平米

抓取步骤（准备工作）

1. 建立文件夹，并命名 getdata

2. 打开RStudio

3. 设置工作目录

4. 开始爬



The image shows a screenshot of an RStudio session. The top part displays a file explorer window with the path '此电脑 > 工作 (F:) > Rcode > getdata'. Below this, the R console shows the following commands and output:

```
> getwd()
[1] "C:/Users/DELL/Documents"
> setwd("F:/Rcode/getdata")
> getwd()
[1] "F:/Rcode/getdata"
> |
```

抓取步骤（网页部分）

1. 找到网址，点击SelectorGadget

网页下角

杭州市普通住宅的标准是什...

买新房，商业贷款流程是怎...

No valid path found.

Clear

Toggle Position

XPath

?

X

2. 选择页码，点击网站页码，变黄

1

2

3

...

100

下一页

a

Clear (566)

Toggle Position

XPath

?

X

3. 点击网页内容，获取结点信息

复兴南苑，两居室，满五唯一，拎包入住... 必看好房

复兴南苑 - 复兴

2室1厅147.9平米 | 南 | 精装 | 低楼层(共7层) | 1998年建 | 板楼

div div

☆ 1人关注 / 10天以前发布

我是中介！ 房东说买房有诀窍

近地铁

VR

.houseInfo, a

Clear (596)

Toggle Position

XPath

?

X

结点名

抓取步骤（网页部分）

4. 点击所有需要抓取的信息



复兴南苑，两居室，满五唯一，拎包入住... 必看好房

复兴南苑 - 复兴

206万

2室1厅 | 47.9平米 | 南 | 简装 | 低楼层(共7层) | 1998年建 | 板楼

单价43007元/平米

1人关注 / 10天以前发布

近地铁

VR房源

随时看房

.title a , a+ a , .followInfo , .totalPrice , .unitPrice span , .hoi

Clear (479)

Toggle Position

XPath

?

X

5. 点击XPath,在弹出对话框 点击确定

hz.lianjia.com 显示

The CSS selector '.LOGCLICKDATA+ .LOGCLICKDATA a , .title a , a+ a , .followInfo , .totalPrice , .unitPrice span , .houseInfo , .house-1st-page-box a' as an XPath is shown below. Please report any bugs that you find with this converter.

```
//*[contains(concat(" ", @class, " "), concat(" ", "LOGCLICKDATA", " ")]
```

确定

取消

6. 点击XPath,在弹出对话框, 以便对应结点名字


抓取步骤（RStudio部分）

1. 安装rvest包，安装dplyr包

2. 读取xml2,rvest,dplyr及stringr

```
library(xml2)
library(rvest)
library(dplyr)
library(stringr)
```

3. 读取网页信息



hz.lianjia.com 显示

The CSS selector '.LOGCLICKDATA+.LOGCLICKDATA a,.title a,a+.a,.followInfo,.totalPrice,.unitPrice span,.houseInfo,.house-1st-page-box a' as an XPath is shown below. Please report any bugs that you find with this converter.

```
//*[contains(concat(" ",@class," "),concat(" ", "LOGCLICKDATA", " " )
```

确定

取消

```
web=read_html(str_c("https://hz.lianjia.com/ershoufang/"),1),encoding = "UTF-8")
```

4. 读取网页结点信息

```
house_name=web %>% html_nodes(".title a") %>% html_text()
```

Data	
web	List of 2
values	
house_name	chr [1:31] "复兴南苑，两居室，满五唯一，拎包入住，诚心出...

抓取步骤（RStudio部分）

```
house_address=web %>% html_nodes(".positionInfo") %>% html_text()
```

web	List of 2
values	
house_address	chr [1:30] "复兴南苑 - 复兴" "云雀苑 - 鼓楼" ...
house_name	chr [1:31] "复兴南苑，两居室，满五唯一，拎包入住，诚心出..."

```
house_inf=web %>% html_nodes(".houseInfo") %>% html_text()
```

```
total_price=web %>% html_nodes(".totalPrice") %>% html_text()
```

```
unit_price=web %>% html_nodes(".unitPrice span") %>% html_text()
```

```
follower=web %>% html_nodes(".followInfo") %>% html_text()
```

Data	
web	List of 2
values	
follower	chr [1:30] "1人关注 / 10天以前发布" "1人关注 / 13天..."
house_address	chr [1:30] "复兴南苑 - 复兴" "云雀苑 - 鼓楼" ...
house_inf	chr [1:30] "2室1厅 47.9平米 南 简装 低楼层(...)"
house_name	chr [1:31] "复兴南苑，两居室，满五唯一，拎包入住，诚心出..."
total_price	chr [1:30] "206万" "279万" "246万" "335万" "725万" ...
unit_price	chr [1:30] "单价43007元/平米" "单价40677元/平米" "单..."

抓取步骤（RStudio部分）

5. 查看异常

house_name

6. 清除异常

house_namer=house_name[1:30]

```
> house_namer
```

```
[1] "复兴南苑，两居室，满五唯一，拎包入住，诚心出售。"  
[2] "云雀苑 2室1厅 279万"  
[3] "精装一年，品牌家居带露台，拎包入住！"  
[4] "4号线南星桥地铁口 5号线年底通车 勇进在旁边"  
[5] "满两年！开发商精装修，业主没住过，户型佳，楼层好。"  
[6] "一梯两户，厨卫全明，南北通，阳光无遮挡"  
[7] "架空一楼 有5平方储藏室 看房有钥匙 价格可谈"  
[8] "业主诚心出售，2017年精装修全屋地暖，可直接拎包入住"  
[9] "凤凰南苑，不临街位置好，中间楼层光照充足"  
[10] "得房率高，房间朝南，交通方便，总价低。"  
[11] "复兴北苑，两房，简单装修，低楼层"  
[12] "耀江文鼎苑 3室2厅 910万"  
[13] "2018年交付次新房三房户型，视野宽阔，楼层位置好"  
[14] "亲亲家园一期 满五年 小区中间 南北通透 看房随时"  
[15] "东河景观房、带车位、多层电梯、一梯一户、品质小区、"  
[16] "世茂滨江峻景湾 大户型 业主自住精装 诚心出售"  
[17] "西溪湿地 府新花园西区沿河景观房 大四房 户型正气"  
[18] "世茂广场 不在限购 地铁口 精装修一居室 诚心出售"  
[19] "金地繁华里，精装修，满两年，小三房。"  
[20] "满2年免增值税，毛坯房，看房随时"  
[21] "赞成美树 精装修 满2年 诚心出售"  
[22] "楼层好，户型好，得房率高，交通便利"  
[23] "一线江景，户型好！楼层好！此房户型方正 小区环境美"  
[24] "满两年！大四房、东边套，40万精装，看房有钥匙"  
[25] "养眼的户型 复古的装修 老幼皆宜的楼层 还不下手！"  
[26] "满二年 电梯花园洋房 房东诚心"  
[27] "银泰城小三房 中间楼层 采光无遮挡 看房方便"  
[28] "阳光城翡丽湾 三房两卫 刚需好房 满两年 无增值税"  
[29] "东冠逸景，自住装修，标准两房，房东诚售。"  
[30] "满2年，三居室，毛坯房，朝南，86.75方"
```

```
> house_name
```

```
[1] "复兴南苑，两居室，满五唯一，拎包入住，诚心出售。"  
[2] "云雀苑 2室1厅 279万"  
[3] "精装一年，品牌家居带露台，拎包入住！"  
[4] "4号线南星桥地铁口 5号线年底通车 勇进在旁边"  
[5] "满两年！开发商精装修，业主没住过，户型佳，楼层好。"  
[6] "一梯两户，厨卫全明，南北通，阳光无遮挡"  
[7] "架空一楼 有5平方储藏室 看房有钥匙 价格可谈"  
[8] "业主诚心出售，2017年精装修全屋地暖，可直接拎包入住"  
[9] "凤凰南苑，不临街位置好，中间楼层光照充足"  
[10] "得房率高，房间朝南，交通方便，总价低。"  
[11] "复兴北苑，两房，简单装修，低楼层"  
[12] "耀江文鼎苑 3室2厅 910万"  
[13] "2018年交付次新房三房户型，视野宽阔，楼层位置好"  
[14] "亲亲家园一期 满五年 小区中间 南北通透 看房随时"  
[15] "东河景观房、带车位、多层电梯、一梯一户、品质小区、"  
[16] "世茂滨江峻景湾 大户型 业主自住精装 诚心出售"  
[17] "西溪湿地 府新花园西区沿河景观房 大四房 户型正气"  
[18] "世茂广场 不在限购 地铁口 精装修一居室 诚心出售"  
[19] "金地繁华里，精装修，满两年，小三房。"  
[20] "满2年免增值税，毛坯房，看房随时"  
[21] "赞成美树 精装修 满2年 诚心出售"  
[22] "楼层好，户型好，得房率高，交通便利"  
[23] "一线江景，户型好！楼层好！此房户型方正 小区环境美"  
[24] "满两年！大四房、东边套，40万精装，看房有钥匙"  
[25] "养眼的户型 复古的装修 老幼皆宜的楼层 还不下手！"  
[26] "满二年 电梯花园洋房 房东诚心"  
[27] "银泰城小三房 中间楼层 采光无遮挡 看房方便"  
[28] "阳光城翡丽湾 三房两卫 刚需好房 满两年 无增值税"  
[29] "东冠逸景，自住装修，标准两房，房东诚售。"  
[30] "满2年，三居室，毛坯房，朝南，86.75万"  
[31] "去登录"
```

开始大量爬（RStudio）

```
i=1:100
```

抓取1-100页信息，定义i向量

```
mydata=data.frame()
```

定义一个空的数据框

```
for(i in 1:100){
```

for 循环,i从1一直到100.
{开始循环内容，用} 结束循环

```
web1=read_html(str_c("https://hz.lianjia.com/ershoufang/pg",i),  
encoding = "UTF-8")
```

抓取网页信息，第i页

```
house_name1=web1 %>% html_nodes(".title a") %>% html_text()
```

房名

```
house_address1=web1 %>% html_nodes(".positionInfo") %>% html_text()
```

地址

```
house_inf1=web1 %>% html_nodes(".houseInfo") %>% html_text()
```

基本信息

```
total_price1=web1 %>% html_nodes(".totalPrice") %>% html_text()
```

总价

```
unit_price1=web1 %>% html_nodes(".unitPrice span") %>% html_text()
```

单价

```
follower1=web1 %>% html_nodes(".followInfo") %>% html_text()
```

关注度

```
house_namer1=house_name1[1:30]
```

修正房名

开始大量爬 (RStudio)

```
house=data.frame(house_namer1,house_inf1,house_address1,unit_price1,total_price1,follower1)
```

创建数据框存储上述信息

```
mydata=rbind(mydata,house)
```

合并行，一次循环合一个house

```
}
```

结束for循环

```
> i=1:100
> mydata=data.frame()
> for(i in 1:100){
+ web1=read_html(str_c("https://hz.lianjia.com/ershoufang/pg",i),
+ encoding = "UTF-8")
+ house_namer1=web1 %>% html_nodes(".title a") %>% html_text()
+ house_address1=web1 %>% html_nodes(".positionInfo") %>% html_text()
+ house_inf1=web1 %>% html_nodes(".houseInfo") %>% html_text()
+ total_price1=web1 %>% html_nodes(".totalPrice") %>% html_text()
+ unit_price1=web1 %>% html_nodes(".unitPrice span") %>% html_text()
+ follower1=web1 %>% html_nodes(".followInfo") %>% html_text()
+ house_namer1=house_namer1[1:30]
+ house=data.frame(house_namer1,house_inf1,house_address1,unit_price1,total_price1,follower1)
+ mydata=rbind(mydata,house)
+ }
```

house	30 obs. of 6 variables
mydata	3000 obs. of 6 variables

```
write.csv(mydata,"housedata.csv")
```

导出所爬信息到csv表格

此电脑 > 工作 (F:) > Rcode > getdata

名称	修改日期	类型	大小
housedata.csv	2019/11/22 15:29	XLS 工作表	577 KB

房源信息

house_namer1	house_infi	house_address1	unit_price1	total_p	follower1
1 朝晖苑 运河景观 三房 户型方正	3室1厅 105.7平米 南 简装 13层 朝晖七区	- 朝晖	单价43993元/平米	465万	2人关注 / 5天以前发布
2 此房是双钥匙格局 价格是比较低	2室2厅 42平米 北 精装 20层 高润云杉郡	- 彩虹城	单价30477元/平米	128万	2人关注 / 29天以前发布
3 开元名都 3室2厅 498万	3室2厅 157平米 南 简装 高楼层(共1	开元名都 - 萧山区	单价31720元/平米	498万	9人关注 / 4个月以前发布
4 中国建楼层, 采光无遮挡. 无增值	3室2厅 89.58平米 南 精装 中楼层(	中国铁建青秀城 - 萧	单价41863元/平米	375万	13人关注 / 1个月以前发布
5 满五年免增值税, 单元边套格局	2室2厅 54.67平米 南 简装 中楼层(	城北商贸园 - 申花	单价32925元/平米	180万	7人关注 / 5个月以前发布
6 此房户型好 楼层好, 采光佳 房	3室2厅 137平米 南 简装 高楼层(	江南文苑 - 浦沿	单价36132元/平米	495万	11人关注 / 5个月以前发布
7 钱江新城, 满两年, 采光好 户型	3室2厅 76.35平米 南 精装 低楼层(	盛世钱坤 - 钱江新城	单价78586元/平米	600万	52人关注 / 4个月以前发布
8 阳光城上府小户型边套! 自住精	3室2厅 88.64平米 南 精装 低楼层(	阳光城上府 - 西兴	单价40050元/平米	355万	31人关注 / 1个月以前发布
9 房子开发商装修, 带两块菜地, 朝	2室2厅 83.51平米 东南 精装 中楼层(	杉杉恒和依山郡 - 未	单价14610元/平米	122万	3人关注 / 14天以前发布
10 此房满2年, 房东自住装修, 东边	6室2厅 221.3平米 东南 精装 中楼层(	良渚文化村白鹭郡北 -	单价19883元/平米	440万	26人关注 / 6个月以前发布
11 文二新村 两房朝南 精装带地暖	2室1厅 46.37平米 南 精装 中楼层(	文二新村 - 学军	单价107829元/平米	500万	8人关注 / 27天以前发布
12 德胜东村, 中间楼层, 两房朝南!	2室1厅 55.22平米 南 简装 中楼层(	德胜东村 - 德胜东	单价33503元/平米	185万	7人关注 / 1天以前发布
13 总价低 楼层佳 采光足 交通便利	2室1厅 51.4平米 南 简装 中楼层(	共祥符新村 - 申花	单价32102元/平米	165万	14人关注 / 25天以前发布
14 满五唯一 小区中间位置 不沿马	2室1厅 51.59平米 南 简装 中楼层(	水陆寺巷 - 长庆	单价45940元/平米	237万	20人关注 / 2个月以前发布
15 三开间朝南, 通透户型, 中间楼	3室2厅 102.54平米 南 精装 中楼层(	明珠公寓 - 翠苑	单价40960元/平米	420万	2人关注 / 11天以前发布
16 自住精装小三房, 朝南大阳台, 书	3室2厅 91.56平米 南 精装 中楼层(	绿城翡翠湾 - 翡翠城	单价37462元/平米	343万	19人关注 / 28天以前发布
17 湾天地精装跃层两室, 层高5.8	2室2厅 47.41平米 东南 精装 17层	保利湾天地二期 - 沿	单价17929元/平米	85万	8人关注 / 18天以前发布
18 好房出售 3室2厅2卫 采光好 带	3室2厅 109.37平米 南 精装 高楼层(	新苑小区 - 塘栖	单价14173元/平米	155万	23人关注 / 3个月以前发布
19 融创金成英特学府轻轨房三开间	3室2厅 88.65平米 南 毛坯 低楼层(	金成英特学府 - 闲林	单价25945元/平米	230万	8人关注 / 1个月以前发布
20 此房南北通透, 前后无遮挡 业主	3室2厅 89平米 南北 精装 中楼层(	中海西溪华府 - 西溪	单价49214元/平米	438万	30人关注 / 3个月以前发布
21 金沙学府 4室2厅 385万	4室2厅 133.22平米 南 精装 高楼层(	金沙学府 - 高教园区	单价28900元/平米	385万	8人关注 / 3个月以前发布
22 叠彩园, 刚需好房, 满两年, 房	2室2厅 92.33平米 南 精装 中楼层(	合景叠彩园 - 未来科技	单价39533元/平米	365万	4人关注 / 4天以前发布
23 近九堡地铁站, 总价比较低, 适合	2室1厅 48.31平米 南北 简装 高楼层(	都东公寓 - 九堡	单价33120元/平米	160万	139人关注 / 10个月以前发布
24 一楼两户, 两房朝南, 满五且唯	3室1厅 65.25平米 南 精装 低楼层(	大关东一苑 - 大关	单价32951元/平米	215万	8人关注 / 8天以前发布
25 房子满2年 结构好 楼层佳 看房	1室1厅 38.18平米 东 简装 高楼层(	三里亭东四区 - 三里亭	单价35359元/平米	135万	0人关注 / 10天以前发布
26 景芳二区 1室1厅 132万	1室1厅 30.42平米 南 简装 中楼层(	景芳二区 - 景芳	单价43393元/平米	132万	4人关注 / 6天以前发布
27 自住精装修临近地铁公园商场温	3室2厅 89平米 南北 精装 中楼层(	昆仑天禧 - 丁桥	单价31461元/平米	280万	0人关注 / 6天以前发布
28 世茂广场 不限购 地铁口 精装	1室1厅 67.17平米 南 精装 高楼层(	世茂滨江商业中心 - 文	单价13399元/平米	90万	36人关注 / 16天以前发布
29 随时签约, 三证满两年免缴增值	3室2厅 87.46平米 东南 精装 低楼层(	西溪华东园 - 翡翠城	单价34874元/平米	305万	20人关注 / 2个月以前发布
30 众安理想湾 3室1厅 192万	3室1厅 112平米 南 毛坯 低楼层(	共众安理想湾 - 临平	单价17143元/平米	192万	27人关注 / 15天以前发布
31 满五年并且唯一一套, 中间楼层,	2室1厅 44.72平米 南 简装 中楼层(	翠苑二区 - 翠苑	单价40922元/平米	183万	183人关注 / 7个月以前发布
32 总高2层两房朝南, 一梯两户, 1	92室1厅 58.47平米 南 简装 低楼层(	董家弄 - 信义坊	单价34206元/平米	200万	25人关注 / 4个月以前发布
33 2016年的精装, 家电具齐全, 拎	3室1厅 88平米 南 精装 高楼层(	共32 富越香郡 - 桥西	单价42046元/平米	370万	46人关注 / 1个月以前发布
34 名城博园 精装修 带个车位	3室2厅 88.18平米 南 精装 低楼层(	嘉凯城名城博园 - 勾	单价26651元/平米	235万	7人关注 / 1个月以前发布
35 云杉郡 两房 朝南 看房有钥匙	2室2厅 51.04平米 南 精装 23层	高润云杉郡 - 彩虹城	单价25079元/平米	128万	18人关注 / 2个月以前发布
36 求是里带花园 开发商装修 大	2房2室1厅 109平米 南北 精装 低楼层(	坤和求是里 - 西溪	单价41285元/平米	450万	96人关注 / 10个月以前发布
37 民用水电, 通燃气. 4.98米层高!	2室2厅 50平米 南 精装 中楼层(	共19 迪凯运河印象 - 万	单价26000元/平米	130万	11人关注 / 一年前发布
38 清爽装修 两居室 拎包入住 看	房2室1厅 75.51平米 南 简装 中楼层(	蜜花园永庆坊 - 拱宸	单价26752元/平米	202万	170人关注 / 5个月以前发布
39 1室1厅 西南 交通方便 配套	1室1厅 50.07平米 南 西 简装 高楼层(	门自由21世纪 - 文	单价53526元/平米	268万	14人关注 / 5个月以前发布
40 难得户型, 两房朝南, 可看江景,	2室1厅 56.47平米 南 简装 高楼层(	凤凰南苑 - 南星	单价45866元/平米	259万	3人关注 / 6天以前发布
41 文泽路, 老物美大三房, 文海上	3室1厅 144平米 南 毛坯 中楼层(	共11 银公寓 - 高教园区	单价20695元/平米	298万	4人关注 / 3天以前发布
42 锦浦江岸公寓 万科品质 一线江	3室2厅 105平米 南 西 精装 高楼层(	铁建万科江湾城 - 义	单价21905元/平米	230万	25人关注 / 1个月以前发布
43 西溪湿地 府新花园西区沿河景观	4室2厅 117.52平米 南 简装 低楼层(	府新花园西区 - 文三	单价48503元/平米	570万	8人关注 / 19天以前发布
44 金都复宫 3室2厅 185万	3室2厅 89.29平米 南 毛坯 中楼层(	金都复宫 - 临平	单价20720元/平米	185万	1人关注 / 5天以前发布
45 房东诚心出售, 随时可看, 距景	房1室1厅 37.15平米 南 简装 高楼层(	景芳五区 - 景芳	单价37147元/平米	138万	78人关注 / 29天以前发布



我也会爬数据了!

save.image("dataget.RData")

dataget.RData

housedata.csv


2019/11/22 15:38 RDATA 文件

11 KB

2019/11/22 15:36 XLS 工作表

536 KB

**讨论：
数据不能乱爬！**



豆瓣250

豆瓣电影 Top 250

☐ 我没看过的(182)

1



肖申克的救赎 / The Shawshank Redemption / 月黑高飞(港) / 刺激1995(台) [可播放]

导演: 弗兰克·德拉邦特 Frank Darabont 主演: 蒂姆·罗宾斯 Tim Robbins / ...
1994 / 美国 / 犯罪 剧情

★★★★★ 9.6 1472685人评价

“希望让人自由。”

想看 看过

2



霸王别姬 / 再见，我的妾 / Farewell My Concubine [可播放]

导演: 陈凯歌 Kaige Chen 主演: 张国荣 Leslie Cheung / 张丰毅 Fengyi Zha...
1993 / 中国大陆 香港 / 剧情 爱情 同性

★★★★★ 9.6 1091021人评价

“风华绝代。”

想看

3



这个杀手不太冷 / Léon / 杀手莱昂 / 终极追杀令(台) [可播放]

导演: 吕克·贝松 Luc Besson 主演: 让·雷诺 Jean Reno / 娜塔莉·波特曼 ...
1994 / 法国 / 剧情 动作 犯罪

★★★★★ 9.4 1339853人评价

“怪蜀黍和小萝莉不得不说的故事。”

想看 看过

课程作业：用rvest可以爬取豆瓣电影Top 250，并导出每部电影的名字、年份、出品国以及剧情分类，并用R markdown撰写报告(html或pdf)。

豆瓣250

简书

首页

下载APP

搜索



用R语言rvest包爬取豆瓣电影top250并做可视化分析



刘阿星呀 [关注](#)

2018.07.31 00:42:24 字数 1,850 阅读 3,486



3赞



赞赏

爬取网页数据：

1.安装selectorGadget插件

这个插件是安装在谷歌浏览器上的，长这样：



安装方法：先下载这个插件，是一个文件：

SelectorGadget.crx

2017/11/18 9:43

CRX 文件

80 KB



- 安装相关的包
 - `install.packages("rvest")`
- 使用Chrome浏览器安装插件
 - `selectorGadget`

一、访问读取网页



#访问读取网页

library("rvest")

url='https://movie.douban.com/top250'|

webpage=read_html(url)

豆瓣电影

搜索电影、电视剧、综艺、影人



2021 豆瓣
年度电影榜单

影讯&购票

选电影

电视剧

排行榜

分类

影评

2021年度榜单

2021书影音报告

豆瓣电影 Top 250

☐ 我没看过的

1



肖申克的救赎 / The Shawshank Redemption / 月黑高飞(港) / 刺激1995(台) [可播放]

导演: 弗兰克·德拉邦特 Frank Darabont 主演: 蒂姆·罗宾斯 Tim Robbins / ...
1994 / 美国 / 犯罪 剧情

★★★★★ 9.7 2622242人评价

“希望让人自由。”

2



霸王别姬 / 再见，我的妾 / Farewell My Concubine [可播放]

导演: 陈凯歌 Kaige Chen 主演: 张国荣 Leslie Cheung / 张丰毅 Fengyi Zha...
1993 / 中国大陆 中国香港 / 剧情 爱情 同性

★★★★★ 9.6 1947086人评价

“风华绝代。”

3




阿甘正传 / Forrest Gump / 福雷斯特·冈普 [可播放]

导演: 罗伯特·泽米吉斯 Robert Zemeckis 主演: 汤姆·汉克斯 Tom Hanks / ...
1994 / 美国 / 剧情 爱情

★★★★★ 9.5 1971549人评价

豆瓣用户每天都在对“看过”的电影进行“很差”到“力荐”的评价，豆瓣根据每部影片看过的人数以及该影片所得的评价等综合数据，通过算法分析产生豆瓣电影 Top 250。



豆瓣
让好电影来找你

二、Selector Gadget获取 特定CSS选择器



要爬取网页上的数据，首先要知道的是，网页上的数据处于网页中的什么位置



肖申克的救赎 / The Shawshank Redemption / 月黑高飞(港) / 刺激1995(台) [可播放]

导演: 弗兰克·德拉邦特 Frank Darabont 主演: 蒂姆·罗宾斯 Tim Robbins / ...
1994 / 美国 / 犯罪 剧情

★★★★★ 9.7 2622242人评价

“希望让人自由。”

2



霸王别姬 / 再见，我的妾 / Farewell My Concubine [可播放]

导演: 陈凯歌 Kaige Chen 主演: 张国荣 Leslie Cheung / 张丰毅 Fengyi Zha...
1993 / 中国大陆 中国香港 / 剧情 爱情 同性

★★★★★ 9.6 1947086人评价

“风华绝代。”

3




阿甘正传 / Forrest Gump / 福雷斯特·冈普 [可播放]

导演: 罗伯特·泽米吉斯 Robert Zemeckis 主演: 汤姆·汉克斯 Tom Hanks / ...
1994 / 美国 / 剧情 爱情

★★★★★ 9.5 1971549人评价

em

得的评价等综合数据，通过算法分析产生豆瓣电影 Top 250。



豆瓣
让好电影来找你

Clear (25)

Toggle Position

XPath

?

X

三、爬取特定信息





#使用css选择爬取排名

```
rank_data_html=html_nodes(webpage, 'em') #html_nodes读取节点内容
```

```
rank_data=html_text(rank_data_html) # html_text提取对应节点的文本
```

```
head(rank_data)
```

```
rank_data=as.numeric(rank_data)
```

```
head(rank_data)
```

```
> rank_data=as.numeric(rank_data)
```

```
> head(rank_data)
```

```
[1] 1 2 3 4 5 6
```

```
> |
```




#使用css选择爬取标题

```
title_data_html=html_nodes(webpage, '.title:nth-child(1)')
```

```
title_data=html_text(title_data_html)
```

```
head(title_data)
```

#使用css选择爬取描述

```
description_data_html=html_nodes(webpage, '.inq')
```

```
description_data=html_text(description_data_html)
```

```
head(description_data_html)
```

```
[1] "肖申克的救赎"      "霸王别姬"          "阿甘正传"          "泰坦尼克号"      "这个杀手不太冷"
```

```
[6] "美丽人生"
```

> #使用css选择爬取描述

```
> description_data_html=html_nodes(webpage, '.inq')
```

```
> description_data=html_text(description_data_html)
```

```
> head(description_data_html)
```

```
{xml_nodeset (6)}
```

```
[1] <span class="inq">希望让人自由。</span>
```

```
[2] <span class="inq">风华绝代。</span>
```

```
[3] <span class="inq">一部美国近现代史。</span>
```

```
[4] <span class="inq">失去的才是永恒的。 </span>
```

```
[5] <span class="inq">怪蜀黍和小萝莉不得不说的故事。</span>
```

```
[6] <span class="inq">最美的谎言。</span>
```



☐ 我没看过的

1



肖申克的救赎 / The Shawshank Redemption / 月黑高飞(港) / 刺激1995(台) [可播放]

导演: 弗兰克·德拉邦特 Frank Darabont 主演: 蒂姆·罗宾斯 Tim Robbins /...

1994 / 美国 / 犯罪 剧情

div p

★★★★★ 9.7 2622242人评价

希望让人自由。 ”

2



霸王别姬 / 再见，我的妾 / Farewell My Concubine [可播放]

导演: 陈凯歌 Kaige Chen 主演: 张国荣 Leslie Cheung / 张丰毅 Fengyi Zha

爬取电影年份year、国家country、类型genera部分



```
#爬取电影类型gener、年份year、国家country部分
total_data_html<-html_nodes(webpage,'.bd p:nth-child(1)')
total_data<-html_text(total_data_html)
total_data<-strsplit(total_data,'\n')#按\n来划分内容，向量变成了列表
total_data[1]<-NULL#爬下来的第一个元素是“豆瓣”，是不要的，要删掉
total_data<-lapply(total_data,function(x){x[-c(1,2,4)]})#去除不要的内容，只保留
total_data<-unlist(total_data)#将列表转为向量再操作
total_data<-strsplit(total_data,'/')
#选择电影类型gener部分
gener_data<-lapply(total_data,function(x){x[-c(1,2)]})
gener_data<-unlist(gener_data)
gener_data<-strsplit(gener_data,' ')
gener_data<-lapply(gener_data,function(x){x[1]})
gener_data<-unlist(gener_data)
#选择年份部分
year_data<-lapply(total_data, function(x){x[-c(2,3)]})
year_data<-unlist(year_data)
year_data<-sub("^\\s+", "", year_data)
#选择国家部分
country_data<-lapply(total_data, function(x){x[-c(1,3)]})
country_data<-unlist(country_data)
country_data<-strsplit(country_data,' ')
country_data<-lapply(country_data, function(x){x[1]})
country_data<-unlist(country_data)
```

全部爬取下来，对
total_data部分进行
字符串切割直到自
己所需的字段

四、批量爬取





25



怦然心动 / Flipped / 萌动青春 / 青春萌动 [可播放]

导演: 罗伯·莱纳 Rob Reiner 主演: 玛德琳·卡罗尔 Madeline Carroll / 卡...

2010 / 美国 / 剧情 喜剧 爱情

★★★★★ 9.1 1669486人评价

真正的幸福是来自内心深处。 ”

ol li

<前页

1

2

3

4

5

6

7

8

9

10

后页>

(共250条)

```
for (i in 0:9) {  
  url<-paste('https://movie.douban.com/top250?start=',25*i,'&filter=&type=',sep='')  
  webpage<-read_html(url)  
  
  # 具体需要爬取的信息|  
  
}
```



#将爬取的特征整合到一个数据框

```
if(i==0){  
  rank<-rank_data  
  title<-title_data  
  description<-description_data  
  year<-year_data  
  country<-country_data  
  gener<-gener_data  
  rating<-rating_data  
} else {  
  rank<-c(rank,rank_data)  
  title<-c(title,title_data)  
  description<-c(description,description_data)  
  year<-c(year,year_data)  
  country<-c(country,country_data)  
  gener<-c(gener,gener_data)  
  rating<-c(rating,rating_data)  
}
```



```
movie_df<-data.frame(Rank=rank,Title=title,Rating=rating)
# movie_df<-data.frame(Rank=rank,Title=title,Description=descripti
str(movie_df)
head(movie_df)

write.csv(movie_df,"doubanmovietop250.csv",row.names = FALSE)
```

doubanmovietop250

Rank	Title	Rating
1	肖申克的救赎	9.7
2	霸王别姬	9.6
3	阿甘正传	9.5
4	泰坦尼克号	9.4
5	这个杀手不太冷	9.4
6	美丽人生	9.6
7	千与千寻	9.4
8	辛德勒的名单	9.6
9	盗梦空间	9.4
10	忠犬八公的故事	9.4
11	星际穿越	9.4
12	楚门的世界	9.3
13	海上钢琴师	9.3
14	三傻大闹宝莱坞	9.2
15	机器人总动员	9.3
16	放牛班的春天	9.3
17	无间道	9.3



注意

```
> length(rank)
[1] 250
>
> length(title)
[1] 250
>
> length(descriptic
[1] 241
>
> length(year)
[1] 249
>
> length(country)
[1] 249
>
> length(gener)
[1] 249
>
> length(rating)
[1] 250
```

- 爬取下来的数据不一定就符合要求，比如在我们的例子里，rank、title、rating三个数据是完整的，description、year、country、genera数据是缺失的（爬取可能有不同的结果，也有可能会出现多余的数据）
- 对这些问题数据，需要大家去对照爬下来的数据和原始网页信息，人为进行增删，可以参考[爬取豆瓣TOP250](#)中对缺失数据的处理部分

*Thank you for your
attentions !*
